BUA 项目 · 讨论稿 · 结果截至 2026 年 11 月 8 日

短窗口在线学习，能打败长窗口冻结模型吗？

在线模型每次只读最近 96 步，但部署之后会用陆续到达的真实值不停更新参数。冻结模型每次读更长的历史（512 到 4,096 步），训练完就不再改。我们在 10 个数据集上、用同一套训练预算比较这两种做法。我们还想弄清楚：在线模型占优的地方，靠的是什么？是一路更新把比输入窗口更长的历史“记”进了参数（如果是这样，给冻结模型一个同样长的输入窗口也能做到），还是随时间调整参数本身有用，比如跟上分布漂移，这是长窗口替代不了的。

一句话结论

总体上，在线学习没有赢。

W1024 指输入 1,024 步的冻结模型，其余类推；Naive、ER、PROCEED 是三种在线更新方法。全页的百分数，除特别说明，都是“收益”：在线模型的误差（MSE）比冻结模型低多少。正数表示在线更好，比如 +20% 就是在线误差比冻结低 20%；负数表示冻结更好，比如 −20% 就是在线误差比冻结高 20%（定义见第 2 节）。

- **传统划分 T**（训练/验证/测试 = 60/20/20 或 70/10/20）：3 种在线方法 × 5 档冻结窗口，一共 15 个比较（表 2），冻结长窗口全赢；按中位数算，在线模型的 MSE 比冻结高 12%–49%。对 W512–W1024 的 9 个比较，按数据集重抽样也稳定是冻结更好，10 个数据集里在线更好的最多 1 个。
- **在线式划分 O**（20/5/75）：有输有赢（表 1）。对 W512、W720 在线输；对 W1024、W2048，ER、PROCEED 与冻结基本打平（在线误差比冻结高 2.1% 到低 1.8%）；只有对 W4096 在线明显赢。核对后，主要是这一档冻结模型本身比 W2048 差，主要不是因为换了数据集；为什么变差，推测是训练样本太少（见第 3 节表 3 下面的解释）。按数据集重抽样，O 划分 15 个比较都没有稳定的输赢。
- **继续更新本身**：测试开始时把在线模型复制成两份，一份继续更新、一份冻结。继续更新的那份误差有时能低几个百分点（图 2），但个别运行会训崩，误差比冻结大几个数量级（见讨论问题 2）。
- **成本**：在线模型离线训练更省时间，但部署时每次预测的用时是冻结模型的 3–7 倍（图 4）。
- **补充实验**（第 8 节，11 月 5–8 日四轮，大多是 W1024、H = 96）：把在线学习率调小后，长窗口模型加更新基本不再变差（表 7–9）。冻结模型也在验证集上选学习率、早停以后，从它出发的在线 W1024 仍略好：误差在 O 划分低 3.7%、T 划分低 0.7%（表 15）。但 O 划分的优势主要来自冻结模型只用了最早 20% 的数据：用前 75% 重训一次冻结模型，在最后 20% 上，一路更新的在线误差反而比它高 8.0%（表 16）。同样只用 1,024 步历史时，调好的冻结 W1024 比在线 W96 好，在线误差高 11%–12%（表 17）；不过在线一方的离线训练没调参，两边都不调参时 O 划分是在线好。学习率调小也消除了 PEMS-BAY 上的训崩，但那里在线仍比不更新差（表 18）；预测 336 步时，方向和 96 步一样（表 19）。

还没回答的问题：收益来自更多历史还是来自参数更新，补充实验给了更多证据，但还没完全分开：长窗口模型再加小学习率的更新，还能好一点（表 15）；O 划分里在线的优势，重训一次冻结模型就能拿到（表 16）；同样 1,024 步的历史下，调过参的冻结 W1024 比限制记忆的在线 W96 好，但在线一方没调参，两边都不调参时 O 划分是在线好（表 17）。还没比的是：两边都调参以后同样历史下谁好；同样的计算量下，定期重训和在线更新哪个更划算。Electricity 的 O 划分为什么例外，去掉一个几乎不变的变量重跑的实验（实验 E）已安排，结果还没回来（8.11 节）。

蓝色：在线更好　橙色：冻结更好　灰色：收益在 ±5% 以内

主表和三个对照只整理已有结果，没有新跑实验；“补充实验”一节是 11 月 5–8 日新跑的四轮。每个配置、每个种子的明细另有一份附表，需要可以另发。11 月 9 日这一版新增第 8.6–8.11 节（表 15–20，第三、四轮）；前文里被新结果改变的说法一并改了，原来的表 15（前一轮研究）改叫表 21。

第 1 节 · 设计

在时刻 t，两个模型各看到什么



图 1　示意图，不按比例。两个模型都先在训练集上离线训练。之后在线模型先在验证集上照样边预测边更新（预热），再在测试集上继续，所以它部署后用过的历史 K(t) 每一步都在变长（训练集两边都用过，不算在内）。K(t) 一旦超过最长的冻结窗口（4,096 步），就找不到看过同样多历史的冻结模型，所以对照 3 只能用测试期最开头的一小段。

对照 1 · 实用比较

哪种部署方式更准?

在线模型（W = 96）分别对比 W = 512、720、1,024、2,048、4,096 的冻结模型，每档窗口单独报告。

结果

T 划分冻结全赢；O 划分有输有赢（表 1、表 2）。

对照 2 · 同一起点

继续更新本身有没有用?

测试开始时把在线模型复制成两份：一份继续更新，另一份从此冻结。

结果

部分运行误差能低几个百分点，但个别运行会训崩，误差大到离谱（图 2）。

对照 3 · 同等历史

收益是不是只因为看了更多历史?

在每个时刻 t，找窗口不短于 K(t) 的最短冻结模型来比；找不到就跳过这个时刻。

结果

这样比回答不了。能这样比的时间只占测试期很小一部分（占比的中位数：O 划分 1.8%，T 划分 0%；图 3、表 6）。第 8.8 节换了一种比法（限制在线记忆）：同样 1,024 步的历史，调好的冻结 W1024 更好。

第 2 节 · 实验设置

同一套代码、同一套训练预算、不偷看未来

数据集	ETTh1、ETTh2、ETTm1、ETTm2、Electricity、Weather、Solar、PEMS-BAY、PEMS08、北京空气质量[1]

数据划分（训练/验证/测试，%）	**O 在线式：**10 个数据集都是 20/5/75，是在线预测论文里常用的划分：训练段短、测试期长。在线模型从验证期起就边预测边更新；冻结模型的验证集只用来选学习率。 **T 传统：**ETT、PEMS08、北京为 60/20/20；Electricity、Weather、Solar、PEMS-BAY 为 70/10/20。
骨干网络	DLinear、PatchTST，用同一份 OnlineTSF 代码
在线方法（W = 96）	Naive：每有新的真实值到齐就直接微调 · ER：经验回放，更新时混入缓存里的旧样本（缓存 500 条，每次回放 8 条，回放损失权重 0.2）· PROCEED：先估计概念漂移、再据此调整参数的在线适配方法
冻结窗口	W = 512、720、1,024、2,048、4,096；不是每个数据集和骨干都有全部窗口[2]。另外训练了冻结 W96（和在线一样只读 96 步，只是不更新），它不在对照 1 的主表里，单独放在“主结果”一节的方框里；“更新本身有没有用”看对照 2 更干净，因为那里两份模型连起点都一样。
预测长度与种子	H = 24、96、336；种子 2024、2025、2026
训练预算	所有模型一样：FP32、batch 32、Adam、MSE 损失、训练 50 轮、不早停、取最后一轮。为了公平，同一场景（同一数据集、骨干、划分、H）里所有窗口都预测同一批训练目标：训练起点按该场景最长的窗口对齐，短窗口不会因为输入短而多拿样本。学习率在 1e-4、3e-4、1e-3 中选一个所有窗口共用的：用种子 2024 在验证集上给三个学习率在每档窗口里排名，取平均名次最好的（平局取小）；其他种子、在线模型的离线训练和在线更新都沿用它。
不偷看未来	在 u 时刻发出的预测，要等它预测的 H 个真实值全部到齐（当前时刻 t ⩾ u + H）才评分、才拿来更新。
怎么打分	**收益 = (冻结误差 − 在线误差) ÷ 冻结误差**，正数表示在线更好。例：冻结 MSE 0.50、在线 0.40，收益 +20%；在线 0.60，收益 −20%；在线是冻结的 3.5 倍，收益 −250%。收益最高 +100%，往下没有下限，所以比较正负两边时请换成倍数看：+64% 相当于冻结误差是在线的 2.8 倍，−250% 是在线误差是冻结的 3.5 倍。极少数误差暴增的运行会把均值拖到天文数字，所以全页用中位数。误差用训练集标准化后的尺度，只在两者都发出了预测的同一批时刻上累计。表里的数都是多组配对的中位数。
一组配对	放在一起直接比的两次运行：数据集、骨干、划分、预测长度 H、种子、在线方法全都相同，在同一批测试时刻上各算一个 MSE，得到一个收益值。例：ETTm1 · DLinear · O 划分 · H = 96 · 种子 2024 · ER，在线 W96 对冻结 W1024，这是一组配对。一格最多 10 个数据集 × 2 个骨干 × 3 个 H × 3 个种子 = 180 组；某个窗口在某个数据集上跑不了，或者某次运行没有可用结果，对应的配对就不存在，那一格就不到 180 组。表里的 n 和“配对数”都是指这个。对照 1 里冻结的一方是单独训练的 W 步冻结模型；对照 2 里是同一个在线模型在测试开始时复制出来的副本。
不跨划分比绝对误差	O 和 T 的测试期不同（O 测后 75%，T 测后 20%），训练量也不同，所以只比较同一划分里在线和冻结的相对差。

[1] 北京数据用 Quotsoft 原始数据重建（7 个变量，小时级，2014 年 5 月到 2018 年 6 月），保留真实的缺测位置；数值不能和 BasicTS 版本直接对比。[2] 缺窗口有两种原因。一是训练段太短：O 划分里 ETTh1、ETTh2 的训练段只有 2,880 步，最长到 W1024；PEMS08 有 3,571 步，最长到 W2048；Electricity 的 W4096 只有 H = 24、96。T 划分训练段够长，DLinear 在 10 个数据集上都有 W4096。二是 PatchTST 的资源限制，它的最长窗口：ETT 和北京 4,096；Weather 2,048；Solar、PEMS08 1,024；Electricity、PEMS-BAY 720。原因和“分数据集”一节讲的一样：PatchTST 的显存和计算量随变量数和输入长度一起涨，超过资源上限的窗口没有跑。

第 3 节 · 对照 1 · 实用比较

传统划分下，冻结长窗口全面占优

怎么读：表 1（O 划分）和表 2（T 划分）每一格是在线模型（W = 96）相对某一档冻结窗口的 MSE 收益中位数（%），n 是参与的配对数。例：O 划分 Naive 对 W512 是 −22.8%，意思是在这 180 组配对（10 个数据集 × 2 个骨干 × 3 个 H × 3 个种子，全齐）里，按中位数算，在线模型的 MSE 比冻结 W512 高约 23%。个别格子是 179 组：北京 DLinear 有个别运行的记录不完整，按事先定的规则剔除。

表 1　O · 在线式划分（训练/验证/测试 = 20/5/75）

冻结 W	512	720	1,024	2,048	4,096
Naive	−22.8 n 180	−34.2 n 180	−12.0 n 162	−19.9 n 108	+17.0 n 87
ER	−10.3 n 179	−9.9 n 179	−2.1 n 161	−1.7 n 107	+30.8 n 86
PROCEED	−14.4 n 180	−14.6 n 180	+1.1 n 162	+1.8 n 108	+32.1 n 87

表 2　T · 传统划分（60/20/20 或 70/10/20）

冻结 W	512	720	1,024	2,048	4,096
Naive	−48.0 n 179	−49.2 n 179	−41.5 n 162	−28.3 n 144	−20.1 n 135
ER	−35.7 n 179	−34.4 n 179	−24.7 n 162	−19.0 n 144	−16.5 n 135
PROCEED	−36.3 n 179	−35.0 n 179	−23.3 n 162	−15.1 n 144	−12.3 n 135

冻结更好　⩽ −50　−50…−20　−20…−5　±5　5…20　20…50　⩾ 50　在线更好

- T 划分每一格都是冻结更好。按数据集重抽样（随机重抽 10 个数据集 2,000 次，看中位数落在哪），对 W512–W1024 的 9 格，95% 区间都在 0 以下，也就是在线误差稳定更高；10 个数据集里在线更好的最多 1 个。对 W2048、W4096 的 6 格，有 5 格的区间跨过 0。
- O 划分对 W512、W720 冻结更好；对 W1024、W2048，ER、PROCEED 与冻结基本打平；对 W4096 在线明显更好。但按同样的重抽样，O 划分 15 格的 95% 区间都跨过 0，包括对 W4096 的三格，所以 O 划分的输赢都不算稳。
- 三种在线方法里，Naive 在每一格都最差；ER 和 PROCEED 接近。
- 每一列的配对不一样：W512 有约 180 组，O 划分的 W4096 只有 86–87 组（T 划分 135 组）。比如从 W720 到 W1024 少掉的 18 组，正好是 PatchTST 在 Electricity 和 PEMS-BAY 上的配对；这两个数据集明显偏向冻结（看表 5 里 DLinear 那几格），少了它们，W1024 这一列就显得对在线更有利。所以不能把一行从左往右读成趋势。
- 换成 MAE，对在线更友好。O 划分对 W1024，Naive、ER、PROCEED 的 MAE 收益是 −1.6%、+4.8%、+4.9%（正数 = 在线误差更低），MSE 则是 −12.0%、−2.1%、+1.1%；T 划分（同样对 W1024）MAE 仍为负（−18.1%、−13.0%、−11.6%，在线误差更高）。MSE 对大误差更敏感，所以这提示在线模型的典型误差不差，但偶尔会有更大的误差。

中位数会掩盖极端值。PROCEED 对 W1024（O 划分）的收益中位数是 +1.1%（在线误差低 1.1%），均值却是 −2,595%；对 W512（T 划分）的均值约为 -1.2×10^{11}%。均值是被个别训崩的运行拖成天文数字的（见讨论问题 2）；这些值都保留着，没有删。

为什么对 W4096 反而是在线赢？

已用现有结果核对：主要是冻结 W4096 本身比 W2048 差，换了一批数据集只解释了一小部分

W4096 这一格少了哪些数据集。O 划分的训练段只占 20%：ETTh1、ETTh2 只有 2,880 步，PEMS08 只有 3,571 步，都比 4,096 短，冻结 W4096 连一个训练样本都凑不出来。所以这三个数据集不参与这一格：不算输也不算赢，也没有换成短窗口凑数，只是不在这一格的中位数里。左边几格它们照常参与：ETTh1、ETTh2 到 W1024 为止（W2048 扣掉 2,048 步后只剩约 500–800 个训练样本，研究认

为太少，没有跑），PEMS08 到 W2048（只有 DLinear；PatchTST 到 W1024）。PatchTST 的 W4096 又只有 ETTm1、ETTm2 和北京。结果 O 划分的 W4096 只剩 7 个数据集、87 组配对，W512 则是 10 个数据集、180 组。T 划分训练段长，10 个数据集每一格都在。

把数据集固定下来再比。只用同时有 W4096 的这 87 组配对（ER 是 86 组），看在线对 W2048 和对 W4096 的收益（表 3）：

表 3　固定数据集后，在线对 W2048 和对 W4096 的收益（O 划分）

O 划分	对 W2048 全部配对	对 W2048 只用这 87 组	对 W4096 同样 87 组
Naive	−19.9%	−7.5%	+17.0%
ER	−1.7%	+2.6%	+30.8%
PROCEED	+1.8%	+4.9%	+32.1%

前两列都是对 W2048，差别只是换了一批数据集：在线好看了 3–12 个百分点。后两列数据集完全相同，只把冻结窗口从 2,048 换成 4,096：又涨了 25–28 个百分点。在这 87 组里，按逐配对比值的中位数，冻结 W4096 的 MSE 是冻结 W2048 的 1.24 倍，97% 的配对里 W4096 更差；T 划分里这个比值只有 1.06。

冻结 W4096 为什么会变差（推测）。同一场景里所有窗口共用同一批训练样本，O 划分训练段短，样本本来就少；W4096 的输出层参数比 W2048 多一倍（两个骨干的输出层都随 W 线性增长），又固定训练 50 轮、不早停，更容易过拟合。所以“对 W4096 在线赢”说明的是这一档冻结模型在训练数据少时不好用，不能当成在线方法胜过长窗口的证据。

同样只读 96 步：在线 W96 对冻结 W96

主表的做法下，T 划分里更新反而让短窗口模型更差，O 划分基本打平；把在线学习率调小以后，两种划分都是在线更好。

怎么读（表 4）：冻结 W96 和在线模型读一样长的输入（最近 96 步），区别只在部署后要不要更新参数。每格是收益中位数：正数表示在线误差更低，负数表示在线误差更高；小字是在线更好的配对数，以及按数据集重抽样的 95% 区间。

表 4　在线 W96 对冻结 W96（主表做法）

在线 W96 对冻结 W96（主表做法）	O 划分	T 划分
Naive	−6.7% 65/180 组；区间 −28.9% 到 +0.8%	−14.1% 12/180 组；区间 −22.9% 到 −6.9%
ER	0.0% 91/179 组；区间 −6.4% 到 +7.3%	−8.1% 22/180 组；区间 −13.6% 到 −4.6%
PROCEED	+2.0% 99/180 组；区间 −6.7% 到 +7.5%	−7.0% 34/180 组；区间 −17.2% 到 −4.0%

- **T 划分：**三种方法都是在线误差更高（Naive 高 14.1%、ER 高 8.1%、PROCEED 高 7.0%），区间都在 0 以下，10 个数据集里在线更好的最多 1 个。
- **O 划分：**ER、PROCEED 与冻结打平（0.0%、+2.0%），Naive 在线误差高 6.7%，区间都跨过 0。分数据集看（ER）：ETTm1、ETTm2、Weather 上在线误差低 11%–25%，PEMS08、Electricity 上高 38%、52%。

- **学习率调小后**（补充实验第一轮，6 组配置）：在线 W96 对冻结 W96，O 划分在线误差低 11.2%（34 条全部在线更好），T 划分低 5.1%（36 条里 29 条）。所以主表里“更新让短窗口变差”，很大程度上也是学习率太大。
- **成本：**两边训练用的是同样的模型和数据，训练时间基本一样；部署时每次预测，在线是冻结 W96 的 3.9 倍（Naive）、6.5 倍（ER）、7.2 倍（PROCEED）。
- **为什么主表不放这一列：**“更新本身有没有用”看对照 2 更干净：那里两份模型连验证期预热都一样，差别只在测试期是否继续更新；这里的在线模型还在验证期预热过。

主结果说明了什么

有数据支持的

- T 划分下，输入够长的冻结模型是很强的基线，短窗口在线学习在每一档窗口上都比不过它。
- O 划分（训练段短、测试期长）下，在线学习能追到基本打平（对 W1024–W2048），但没有稳定超过。
- 单纯持续微调（Naive）最差；加了回放（ER）或漂移适配（PROCEED）明显更好。

我们的猜测（还需要验证）

- O 划分里在线学习追得上来，是因为冻结模型只用前 20% 的数据训练，却要在后面 75% 上一直用下去；在线模型在这 75% 上边测边学，到最后相当于多用了好几倍的数据，也能跟上分布漂移。T 划分训练段长、测试段短，这个优势就小了。可以粗略核对：O 划分只看测试期最后 30%（约等于整条序列的最后 22.5%，和 T 划分的测试期差不多是同一段时间），在线对冻结 W1024 的收益是 ER 0.0%、PROCEED −1.0%、Naive −13.7%，仍远好于 T 划分的 −24.7%、−23.3%、−41.5%；而 O 划分测试期的前 30%，在线反而差得多（ER −16.4%、PROCEED −16.3%、Naive −36.9%）。所以差别不在测的是哪一段时间，在线是越往后越追上来。第 8.7 节的检验（用的是长窗口在线 W1024）支持这个猜测：用前 75% 的数据重训一次冻结模型，它在最后 20% 上反而比在线好。
- 长输入窗口和在线更新可能在补同一样东西：训练结束之后数据发生的变化，比如新的水平、季节和更长的周期。窗口够长时，冻结模型从输入里就能看到这些变化，在线更新能补的就不多了。补充实验的 2×2 在 6 组配置上不支持这个猜测：学习率调小后，更新在 W1024 和 W96 上的好处差不多（见第 8.3 节、表 12）。
- 在这套训练预算下，冻结模型的窗口不是越长越好：同一批配对上，W4096 就比 W2048 差（见表 3）；从多长开始变差，还没有逐档核对。

第 4 节 · 对照 1 · 分数据集

哪些数据集偏向在线，哪些偏向冻结

表 5 比的是什么：只取一个固定切片。在线一方是 ER（输入 96 步，部署时持续更新），冻结一方是 W1024（输入 1,024 步，训练完不再改）。每一格是某个数据集、某个骨干、某种划分下，两者在 9 组配对（3 个预测长度 × 3 个种子）上的 MSE 收益中位数。选 ER 和 W1024 只是为了看数据集之间的差别，不代表最好的方法或窗口。

怎么读一格：ETTh2 · PatchTST · O 是 +64.4%，表示在线模型的 MSE 只有冻结模型的约 36%；PEMS08 · PatchTST · O 是 −245.9%，表示在线模型的 MSE 约是冻结模型的 3.5 倍。

表 5　ER（在线，W = 96）对比冻结 W = 1,024，MSE 收益中位数（%）

数据集	O · 在线式 20/5/75		T · 传统 60/20/20 或 70/10/20	
	DLinear	PatchTST	DLinear	PatchTST
7 个变量				
ETTh1	+5.3	+24.6	+0.1	−2.0
ETTh2	+23.3	+64.4	−0.2	+1.7
ETTm1	−5.4	+6.5	−15.7	−51.4
ETTm2	+18.8	+53.1	−42.5	−48.4
北京空气质量	+20.0	+8.3	−5.0	−23.7
多于 7 个变量				
Weather	−3.6	−17.0	−19.1	−6.7
Solar	−53.8	−35.2	−59.9	−37.7
PEMS08	−55.0	−245.9	−86.8	−195.4
Electricity	−132.3	n/a	−53.8	n/a
PEMS-BAY	−35.3	n/a	−46.6	n/a

北京 DLinear 的 O 划分只有 8 组可用配对（缺 H = 336、种子 2024 那一组，原因见第 5 节）。数值跨度很大（−246% 到 +64%），所以每格都直接标了数字。

为什么 PatchTST 有两格是 n/a

PatchTST 把每个变量当成一条独立的序列送进 Transformer。Electricity 和 PEMS-BAY 各有三百多个变量，一个 batch 的 32 个窗口就是一万多条序列；输入长到 1,024 步时，超出了显存资源上限。实验规定不能为了放得下而减小 batch、降低精度或改训练轮数，所以 PatchTST 在这两个数据集上最长只跑到 W720，W1024 这一格空着。这不代表 PatchTST 不能用在这两个数据集上，也不能当成 0 或失败来算。

- 7 个变量的数据集（ETTh1、ETTh2、ETTm1、ETTm2、北京）在 O 划分上大多偏向在线，ETTh2 最明显：DLinear 在线误差低 23%，PatchTST 低 64%。
- 变量更多的五个数据集（Weather 21 个变量、Solar 137 个、PEMS08 170 个、Electricity 321 个、PEMS-BAY 325 个）在两种划分上都偏向冻结，PEMS08 最明显。
- 同一个数据集，O 和 T 的结论常常相反。例如 ETTm2：O 划分在线误差低 18.8%（DLinear）、53.1%（PatchTST），T 划分在线误差高 42.5%、48.4%。划分方式对结论影响很大。

第 5 节 · 对照 2 · 同一起点

继续更新本身，收益小而且不稳定

测试开始时把在线模型复制成两份：一份继续用到达的真实值更新，另一份从此冻结。两份起点完全一样，差别只在测试期间要不要继续更新。

怎么读：这里一组配对，就是一次在线运行和它自己的冻结副本。例：ETTm1 · DLinear · O 划分 · H = 96 · 种子 2024 · PROCEED 这一次运行，在测试开始那一刻复制成两份，一份继续更新、一份冻结，在同样的测试时刻上各算一个 MSE，得到一个收益值。每种划分、每种方法最多 10 个数据集 × 2 个骨干 × 3 个 H × 3 个种子 = 180 组，“配对数”就是实际有几组。图 2 里的数是这些收益值的中位数：PROCEED 在 O 划分是 +4.66%，表示按中位数

算，继续更新那份的 MSE 比冻结那份低约 4.7%；“109/179 组更好”是说 179 组里有 109 组继续更新那份的 MSE 更低。O 划分的 ER、PROCEED 只有 179 组，少的是北京 · DLinear · H = 336 · 种子 2024：这组运行的记录不完整，按事先定的规则剔除。对照 1 里只有 ER 缺这一组；PROCEED 只在这一节缺，因为缺的是它的冻结副本。

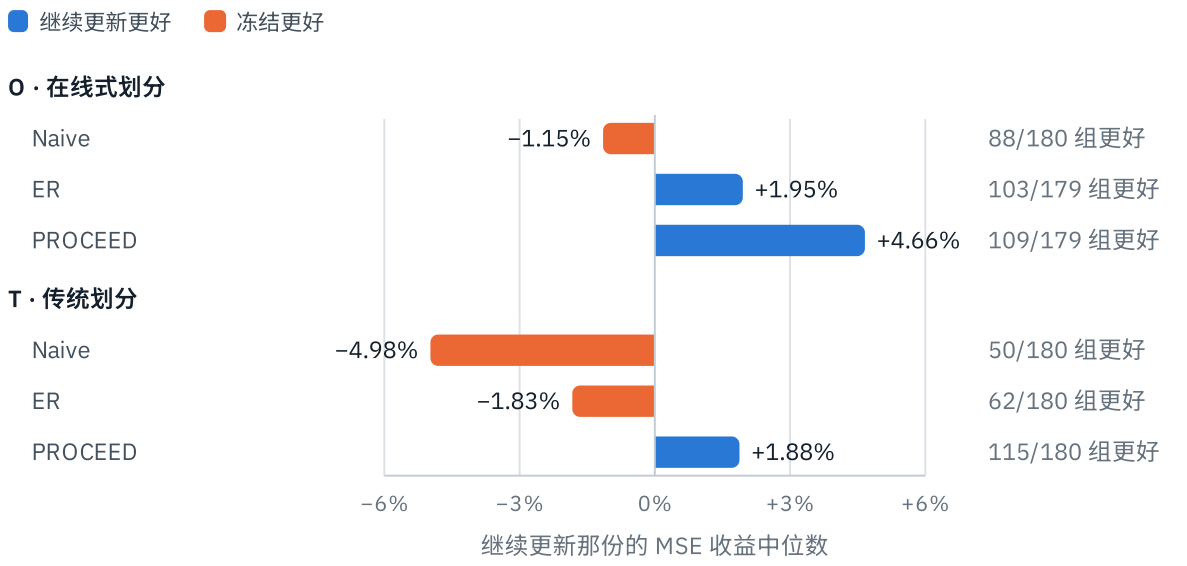


图 2　正数表示继续更新的那份误差更低。Naive 在两种划分里继续更新都更差；ER 在 O 划分更好、T 划分更差；只有 PROCEED 两边都更好，但它的均值被个别训崩的运行拉到 −4,710%（O）和约 -9.2×10^{7}%（T）。

图 2 的数字

划分	方法	配对数	MSE 收益中位数	继续更新更好	MAE 收益中位数
O · 在线式划分	Naive	180	−1.15%	88/180	+0.53%
O · 在线式划分	ER	179	+1.95%	103/179	+0.11%
O · 在线式划分	PROCEED	179	+4.66%	109/179	+1.43%
T · 传统划分	Naive	180	−4.98%	50/180	−1.02%
T · 传统划分	ER	180	−1.83%	62/180	−0.05%
T · 传统划分	PROCEED	180	+1.88%	115/180	+2.88%

补充实验把在线学习率调小以后，长窗口（W1024）上继续更新的好处更清楚：7 个数据集合起来，继续更新那份的误差比冻结副本低 7.0%（O 划分）和 2.7%（T 划分），见第 8.2 节。冻结模型也调参以后（第三轮），继续更新那份的误差比冻结副本低 9.8%（O 划分）和 0.3%（T 划分），见第 8.6 节。

第 6 节 · 对照 3 · 同等历史

想让两边看过的历史一样长，几乎做不到

思路：如果在线模型的收益只是因为它部署后一路“记住”了更长的历史，那么给冻结模型一个同样长的输入窗口，应该也能做到。K(t) 是在线模型从验证期预热开始、到时刻 t 为止一路用过的数据跨度（训练集两边都用过，不算在内）。约定：冻结模型的输入窗口不短于 K(t)，就算它在预测时也“看得到”这段历史。

问题：K(t) 每一步都加 1，而且从验证期就开始累计，很快就超过最长的 4,096 步；之后就找不到同样长的冻结窗口了。

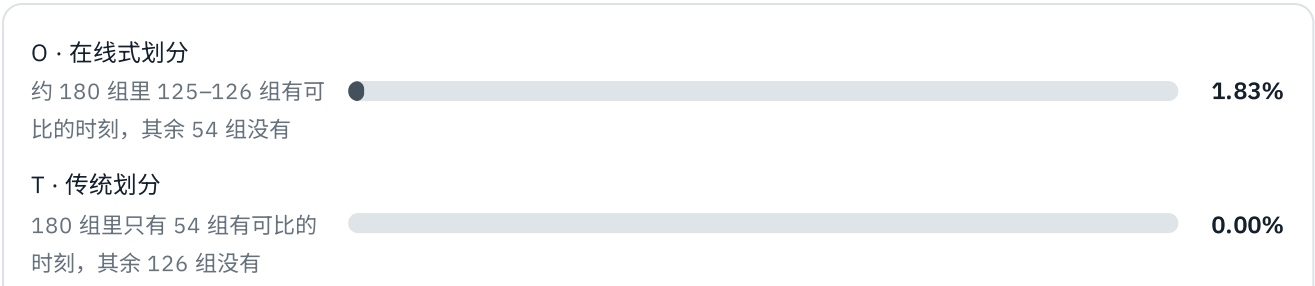


图 3　每次运行的测试期里，能做同等历史比较的时间占比（中位数）。

表 6　同等历史比较：在线对窗口不短于 K(t) 的冻结模型

划分	方法	有可比时刻的运行	可比那一段上的 MSE 收益
O · 在线式划分	Naive	126/180	−1.11%
O · 在线式划分	ER	125/179	+2.40%
O · 在线式划分	PROCEED	126/180	+1.54%
T · 传统划分	Naive	54/180	+34.16%
T · 传统划分	ER	54/180	+35.36%
T · 传统划分	PROCEED	54/180	+34.00%

T 划分那 +34%（在线误差比冻结低 34%）要小心读。能比的只有 54 组运行：ETTh1、ETTh2（两个骨干）和 Electricity、PEMS08（只有 DLinear）。其余 126 组在测试一开始就没得比：T 划分的验证期长（占 10%–20%），在线模型预热完用过的历史已经比能用的最长冻结窗口还长。这 54 组比的都是冻结 W4096，覆盖的是测试期开头约 10%–38% 的时刻。+34% 主要来自其中 36 组 ETTh 运行（按数据集和骨干分组，在线误差低 23%–71%）；Electricity 和 PEMS08 上在线反而更差（误差高 60%、高 399%）。所以它不能代表整个测试期，也不能和对照 1 直接比，比的又正好是前面发现会变差的 W4096。为什么测试开头这段在线赢这么多，还没查。猜测：测试开头紧接验证期，在线模型刚用验证期的数据更新过，冻结模型只见过更早的训练段。第 8.7 节的结果和这个猜测方向一致（冻结模型用上更新的数据后就追上了在线），但没有直接检验这一段。要回答“是不是只靠更多历史”，需要换一种实验设计：第 8.5 节做了一版（把在线记忆限制在 1,024 步），第 8.8 节用小学习率重做了一遍：和调参后的冻结 W1024 比，在线误差高 11%–12%。

第 7 节 · 成本

训练更省，预测更慢

两个比值的定义

- **训练时间比** = 在线模型的离线训练用时 ÷ 冻结模型的离线训练用时。离线训练指部署前在训练集上的训练，只算最后选中的那一次训练，不含在验证集上挑学习率的试跑。小于 1 表示在线模型训练更快。
- **每次预测用时比** = 测试时在线模型每发出一次预测的用时 ÷ 冻结模型的用时。冻结模型只做一次前向计算；在线模型还要用新到的真实值更新参数（ER 还要回放旧样本，PROCEED 还要做适配），这些时间都算在内。大于 1 表示在线模型更慢。

- **例：**ER、O 划分、对比 W1024，训练时间比 0.82×，即在线少用 18% 的训练时间；每次预测用时比 6.39×，即在线每次预测的用时是冻结模型的 6.4 倍。

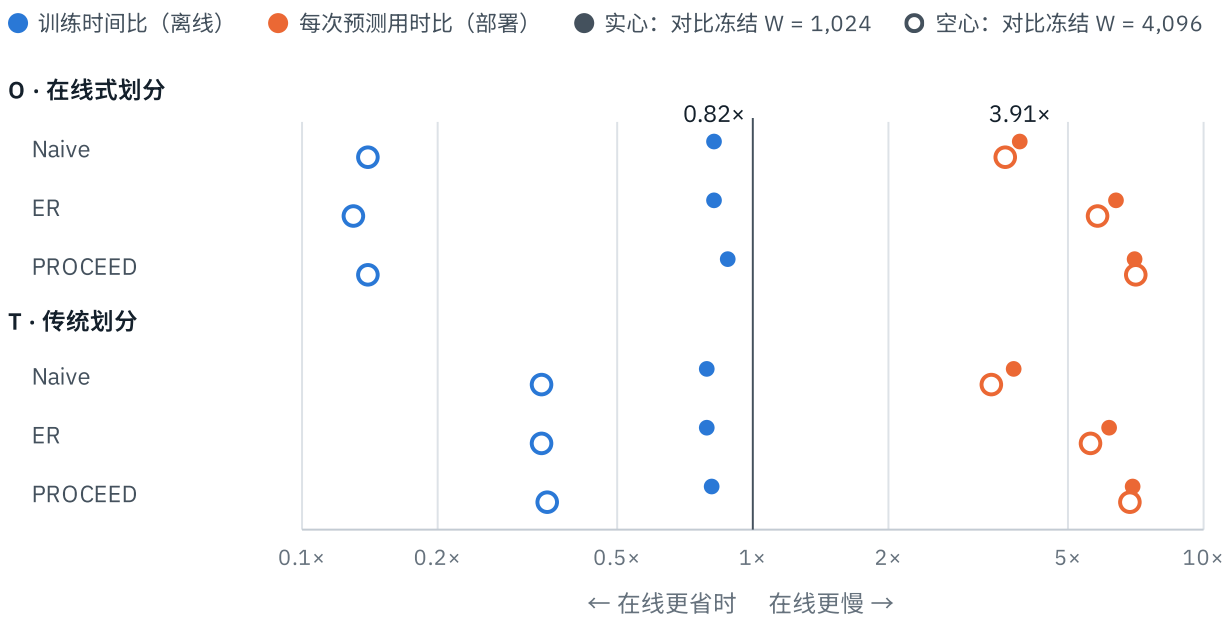


图 4　在线 ÷ 冻结，逐配对比值的中位数，对数坐标。图 4 只画了 W1024 和 W4096 两档；五档窗口全算上，每次预测用时比在 3.4–7.2 倍之间。计时来自共享集群，不是严格控制的基准测试。

图 4 的数字

划分	方法	训练时间比 对比 W1024	每次预测用时比 对比 W1024	训练时间比 对比 W4096	每次预测用时比 对比 W4096
O · 在线式划分	Naive	0.82×	3.91×	0.14×	3.63×
O · 在线式划分	ER	0.82×	6.39×	0.13×	5.82×
O · 在线式划分	PROCEED	0.88×	7.03×	0.14×	7.07×
T · 传统划分	Naive	0.79×	3.79×	0.34×	3.38×
T · 传统划分	ER	0.79×	6.17×	0.34×	5.61×
T · 传统划分	PROCEED	0.81×	6.96×	0.35×	6.86×

在线方法把计算从部署前挪到了部署中。训练时间对 W1024 省 12%–21%，对 W4096 省 65%–87%（因为 W4096 的冻结模型本身训练更慢）；但每次预测的用时是冻结模型的 3–7 倍，部署越久，多花的时间越多。

和同样读 96 步的冻结 W96 比，训练时间基本一样，每次预测在线是它的 3.9 倍（Naive）、6.5 倍（ER）、7.2 倍（PROCEED）。学习率调小也不会让更新更省：第三轮补充实验（冻结也调参的那一轮）里，用小学习率的在线 W1024 每次预测仍是冻结 W1024 的 6.6 倍（4.7–11.8 倍）。

第 8 节 · 补充实验 · 11 月 5–8 日

把在线学习率调小，长窗口模型基本不再被更新带坏

为什么做：主表里在线更新直接沿用离线训练选出的学习率。用主实验另外保留的一批在线 W1024 运行（11 月 1 日缩减范围前已经跑完，倍率 1，不在表 1、表 2 里）算 2×2 时发现，在 9 个数据集上给读 1,024 步的模型（W1024）加上在线更新，误差反而比不更新高 15%–65%。我们猜是在线学习率太大：离线训练每步平均 32 个样本，在线更新每次只用最新到达的一小批，同样的学习率下步子太大。另外，主表也没有回答“同样长的历史下谁更好”。所以补了实验：前两轮看学习率（8.1–8.5 节），第三、四轮补前两轮留下的问题（8.6–8.11 节）。

范围：第一轮（11 月 5 日）：DLinear 跑 ETTh2、ETTm1、Weather、PEMS08，PatchTST 跑 ETTh2、ETTm1；另外查了 PatchTST × PEMS08 · W96 的训崩（这一项用 Naive、PROCEED）。第二轮（11 月 6 日）只做学习率实验的 W1024，补上三个变量多的数据集：Solar（137 个变量）、Electricity（321 个）、PEMS-BAY（325 个），DLinear 三个都跑，PatchTST 只跑 Solar（另两个受显存限制，没有 W1024）。都是 O、T 两种划分，预测长度 H = 96，3 个种子，ER、PROCEED 两种在线方法；冻结模型都用主表训练好的那个，没有新的离线训练。第一轮两个实验各缺 4 条运行（运行故障，没有补跑），第二轮 48 条全部有效。

第三、四轮：前两轮只调了在线学习率，冻结模型没动，还留下几个没回答的问题。第三轮（11 月 7 日）给冻结 W1024 也调学习率并早停，再比一次（8.6 节），并查了 Electricity 的例外（8.11 节）。第四轮（11 月 8 日）做了四个检验：把冻结模型重训到最近（8.7 节）、同样长的历史加小学习率（8.8 节）、PEMS-BAY 的训崩（8.9 节）、预测 336 步（8.10 节）。这两轮的运行全部有效；个别比较要用到的旧结果缺几条，表里写的是实际组数。

这一节的百分比怎么读：除特别说明，都是“收益”：在线的误差（MSE）比冻结低多少。+7.4% 表示在线误差比冻结低 7.4%（在线更好）；−0.7% 表示在线误差比冻结高 0.7%（冻结更好）。倍率 = 在线更新的学习率 ÷ 离线训练的学习率：倍率 1 就是主表的做法（不调小），0.03 表示在线学习率只有离线的 3%。8.6 节以后有三种冻结 W1024：**主表的冻结**（主表的训练方式：所有窗口共用一个学习率、训满 50 轮）、**调参后的冻结**（第三轮：学习率在验证集上选、早停）、**重训的冻结**（第四轮：用前 75% 的数据重新训练）。冻结对冻结、在线对在线的比较，正数表示前面那个误差更低。

8.1 在线学习率是不是太大？

结论：很可能是。调小后，长窗口在线基本不再比冻结差：O 划分在线略好，T 划分还略差 1%–2%，Electricity 的 O 划分是例外。

怎么做：倍率在 0.03、0.1、0.3、1 里挑：只用验证集和种子 2024 挑，挑定后另外两个种子沿用，测试集不参与挑选。冻结模型不动。

表 7，第一轮，同一批配置上不调小和调小比：每格是在线对同窗口冻结的收益中位数，下面是在线更好的组数。一组 = 同一骨干、数据集、划分、种子和在线方法；只用两种倍率都有结果的组。例：W1024 · T 那列，不调小时在线误差比冻结高 16.8%，26 组里只有 3 组在线更好；调小后在线误差低 2.1%，18 组在线更好。

表 7　第一轮：不调小和调小，在线对同窗口冻结

在线相对同窗口冻结	W96 · O	W96 · T	W1024 · O	W1024 · T
不调小（倍率 1，主表的做法）	+8.4% 19/31 组	−4.4% 8/30 组	−0.3% 12/25 组	−16.8% 3/26 组
调小后（验证集挑的倍率）	+9.5% 31/31 组	+6.2% 27/30 组	+10.3% 19/25 组	+2.1% 18/26 组

表 8，第二轮，同样比法：一组 = 同一配置、同一种子的两条在线运行，一条不调小（取自那批保留的在线 W1024 运行），一条用挑中的倍率，各自和同一个冻结模型比。主表里有些配置没有不调小的结果，所以只有 29 组能比，其中 18 组是 Solar；第二轮输得最多的 Electricity · O · ER 和 PatchTST · Solar · T · PROCEED 正好没有。

表 8　同一配置、同一种子：不调小和调小，在线对冻结的收益

数据集 · 划分	组数	不调小（×1）	调小后（挑中的倍率）
Solar · O	9	−19.2%	+5.2%
Solar · T	9	−18.9%	−1.3%
PEMS-BAY · O	3	−14.9%	+8.3%
PEMS-BAY · T	1	−21.9%	−1.6%
Electricity · O	2	−40.8%	−28.1%
Electricity · T	5	−19.7%	−0.8%
O 划分合计	**14**	**−18.5%（3 组在线更好）**	**+5.3%（12 组）**
T 划分合计	**15**	**−19.7%（0 组在线更好）**	**−1.3%（3 组）**
全部	**29**	**−19.2%（3 组在线更好）**	**+1.6%（15 组）**

表 9，两轮合起来，7 个数据集：每格是该数据集全部运行的收益中位数（调小后，在线 W1024 对冻结 W1024），下面是在线更好的条数。

表 9　两轮合起来：调小后在线 W1024 对冻结 W1024

数据集（变量数）	哪一轮	O 划分	T 划分
ETTh2（7）	第一轮	−1.8% 6/12 组	+4.7% 12/12 组
ETTm1（7）	第一轮	+25.5% 10/10 组	+1.7% 9/12 组
Weather（21）	第一轮	+44.7% 6/6 组	−0.9% 0/6 组
Solar（137）	第二轮	+4.9% 12/12 组	−1.5% 3/12 组
PEMS08（170）	第一轮	+22.0% 6/6 组	−0.2% 3/6 组
Electricity（321）	第二轮	−40.3% 0/6 组	−1.1% 0/6 组
PEMS-BAY（325）	第二轮	+8.2% 6/6 组	−1.7% 0/6 组
变量多的 5 个		+7.4% 30/36 组	−1.3% 6/36 组
ETT 两个		+8.1% 16/22 组	+3.8% 21/24 组
全部 7 个		+7.4% 46/58 组	−0.7% 27/60 组

- **不调小时，长窗口在线普遍更差：**第一轮 T 划分在线误差比冻结高 16.8%；第二轮能配对的 29 组高约 19%，只有 3 组在线更好。
- **调小以后：**7 个数据集合起来，O 划分在线误差比冻结低 7.4%（58 条里 46 条在线更好），T 划分高 0.7%（60 条里 27 条在线更好）。
- **按事先写好的判断线：**在线对冻结的中位数 ≥ 0 算“调小学习率能消除劣势”，≤ 约 −5% 算“这组倍率和更新方式下仍更差”，中间不下结论。第一轮 O、T 都成立（在线误差分别低 17.5%、2.3%）。第二轮 O 划分成立（Solar 在线误差低 4.9%、PEMS-BAY 低 8.2%）；T 划分在线误差高 1.5%（24 条里 21 条冻结更好），落在不下结论的区间。
- **Electricity 的 O 划分是例外：**调小后在线误差仍比冻结高 40%（ER 高 46%–81%，PROCEED 高 9%–35%），原因见 8.2、8.11 节。
- **挑中的倍率：**两轮都是最小的 0.03 被挑得最多（第一轮 52 个配置里 33 个，第二轮 16 个里 13 个）；更小的 0.01、0.003 在第三轮试了，0.003 被挑得最多（8.6 节）。
- **训崩的运行没有了：**PatchTST × PEMS08（W96，Naive、PROCEED）的 12 条运行，不调小时 10 条的误差超过冻结 W96 的 10 倍，最大约 37,693 倍；调小后最大 3.2 倍。不再训崩不等于变好：这 12 条仍都比冻结 W96 差（误差是冻结的 1.75–3.18 倍）。

- **这些数有多稳：**按数据集重抽样，7 个数据集合起来，O 划分的 95% 区间是在线误差低 3.8% 到低 26.5%，T 划分是高 1.5% 到低 3.6%（跨过 0）。但 O 划分 7 个数据集里只有 5 个在线更好，数据集太少，区间只能当参考。

表 10　调小学习率后，在线 W1024 对冻结 W1024 的收益

数据集（变量数）· 骨干	O 划分 20/5/75		T 划分 70/10/20	
	ER	PROCEED	ER	PROCEED
Solar（137）· DLinear	+4.5% ×0.03	+3.0% ×0.03	−1.3% ×0.03	−1.6% ×0.03
Solar（137）· PatchTST	+5.2% ×0.3	+7.4% ×0.03	+6.0% ×0.03	−22.5% ×0.1
PEMS-BAY（325）· DLinear	+8.3% ×0.03	+8.2% ×0.03	−1.6% ×0.03	−1.8% ×0.03
Electricity（321）· DLinear	−62.0% ×0.1	−21.2% ×0.03	−0.7% ×0.03	−1.5% ×0.03
每种划分全部 24 条	+4.9% 18/24 条在线更好		−1.5% 3/24 条在线更好	

每格是一个配置 3 个种子的收益中位数，小字是挑中的倍率。

8.2 长窗口在线的优势从哪来，为什么 O 划分好得多

结论：拆开看，测试期继续更新在 O 划分帮得多、T 划分帮得少；O 划分的优势越到测试期后段越大。差别不在测的是哪段时间，更可能在冻结模型训练时见过的数据多少、新旧；8.7 节的检验支持这一点。

怎么拆（表 11）：在线模型在验证期就开始边预测边更新（预热）。测试开始那一刻，把它复制一份冻结起来，叫“预热后的冻结副本”。三个模型都在测试期上算误差，在线对原始冻结的收益（表里的“合计”）就拆成两段：① 预热，这份副本比原始冻结好多少；② 测试期更新，在线比这份副本好多少。按误差的倍数算，每条运行都有“合计 = ① × ②”。例：Electricity · O · ER · 种子 2024 这一条，① 预热后误差变成原始冻结的 2.66 倍（收益 −166%）；② 测试期更新把误差再乘 0.61（收益 +39%）；合计 2.66 × 0.61 = 1.62 倍，也就是在线误差比冻结高 62%。后两列把测试期按时间平均切成 10 段，看前 3 段和后 3 段的收益。

表 11　O 划分：在线的优势从哪来，随时间怎么变

数据集	① 预热	② 测试期更新	合计	测试期 前 30%	测试期 后 30%
ETTh2	+8.5%	−3.5%	−1.8%	+10.5%	+20.9%
ETTm1	+8.8%	+10.4%	+25.5%	+9.5%	+31.9%
Weather	+43.7%	+1.6%	+44.7%	+26.9%	+19.4%
Solar	−7.9%	+12.5%	+4.9%	+11.2%	−4.7%
PEMS08	−1.3%	+20.5%	+22.0%	+2.6%	+32.5%
Electricity	−190.9%	+51.0%	−40.3%	−62.6%	−28.4%
PEMS-BAY	−0.2%	+7.8%	+8.2%	+3.4%	+14.2%
O 划分 7 个合计	**+1.0%**	**+7.0%**	**+7.4%**	**+9.6%**	**+13.1%**
T 划分 7 个合计	**−3.1%**	**+2.7%**	**−0.7%**	**−1.7%**	**+1.4%**

前 7 行是 O 划分，最后两行是 O、T 划分各自 7 个数据集的合计。各列分别取中位数，所以表里的 ①、② 不能直接乘出“合计”，“合计”也不一定落在前后 30% 之间（比如 ETTh2）。一段一段的结果波动大，只看大致趋势。

- **Electricity 的损失主要发生在预热：**预热后误差变成原始冻结的 2.7 倍（ER）和 3.2 倍（PROCEED），测试期更新只追回一部分。学习率只有离线的 3%–10%，不到两个月的预热就差这么多，比较反常。第三轮查了：预热造成的损失几乎全在一个几乎不变的变量上，见 8.11 节。
- **测试期更新：**O 划分 7 个数据集里 6 个在帮忙（ETTh2 例外，误差高 3.5%），合起来让误差低 7.0%；T 划分帮得少，低 2.7%，第二轮的 PEMS-BAY、Electricity 只低 0.2%、0.6%。
- **预热时好时坏：**第一轮 O 划分里，预热让误差低了 11.4%（34 条里 28 条变好），Weather 只靠预热就好了 44%；第二轮三个数据集上，预热几乎都让误差变高。7 个数据集合起来，O 划分误差低 1.0%，T 划分误差高 3.1%。
- **O 划分越往后，在线优势越大：**ETTm1 从测试期前 30% 的误差低 10%，到后 30% 的低 32%；PEMS08 从低 3% 到低 33%；PEMS-BAY 从低 3% 到低 14%。Weather、Solar 相反，越往后越小：Weather 从低 27% 降到低 19%，Solar 最后变成冻结更好；Electricity 一直是冻结更好，后段差距变小。T 划分前后段都在 ±2% 以内。
- **同一段时间上比也一样：**O 划分测试期的后 30% 大约是整条序列的最后 22.5%，和 T 划分的测试期（最后 20%）差不多是同一段时间。这段时间上，O 划分在线误差比冻结低 13%，T 划分基本打平。主表的短窗口在线也是 O 划分有利得多：对冻结 W1024，ER 0.0%、PROCEED −1.0%，T 划分是 −24.7%、−23.3%（见第 3 节）。

猜测（第一条已在 8.7 节检验）：

- O 划分的冻结模型只用前 20% 训练，见过的数据少，越往后也越旧（季节、趋势在变）；在线模型一路用新数据更新，能跟上。T 划分的冻结模型已经用了 60%–70% 的数据，测试期只有 20%，能补的少。检验办法：在最后 20% 之前用全部已有数据重训一次冻结模型，再在最后 20% 上比。第四轮做了（8.7 节）：重训后的冻结模型在最后 20% 上比在线误差还低，支持这个解释。
- Weather 是一整年的数据，O 划分的训练段只有最开始约两个半月；预热用的是紧接着的约 18 天，可能带来了训练段里没有的季节规律。

8.3 长窗口和在线更新是不是在补同一样东西（2×2）

结论：不是。学习率调小后，更新在短窗口和长窗口上都有好处，幅度差不多；长窗口没有替代更新。

我们原来的猜想：长输入窗口和在线更新可能在补同一样东西，就是训练结束之后数据发生的变化（新的水平、季节、更长的周期）。如果是这样，窗口够长时，冻结模型从输入里就能看到这些变化，更新就没什么可补的：更新应该只在短窗口（W96）上有好处，在长窗口（W1024）上没有。

怎么读（表 12）：第一轮的 6 组配置，学习率调小后。“更新的收益”是在线对同窗口的冻结；“长窗口的收益”是 W1024 对 W96（冻结比冻结、在线比在线）。正数表示前者误差更低。

表 12　2×2：更新的收益和长窗口的收益（第一轮，调小后）

学习率调小后	O 划分	T 划分
更新的收益 @ W96（在线 W96 对冻结 W96）	+11.2% 34/34 组	+5.1% 29/36 组
更新的收益 @ W1024（在线 W1024 对冻结 W1024）	+17.5% 28/34 组	+2.3% 24/36 组
长窗口的收益 · 冻结（W1024 对 W96）	+9.7% 18/34 组	+7.5% 24/36 组
长窗口的收益 · 在线（W1024 对 W96）	+4.3% 21/34 组	+7.4% 26/36 组

结果：更新在 W96 和 W1024 上都有好处（合起来分别让误差低 8.0% 和 5.1%），两者几乎一样，所以这个猜想不成立。长窗口的好处在冻结和在线两边也都在，两者大致叠加。要注意 O 划分的“长窗口收益”：ETTh2 的训练段短，冻结 W1024 比冻结 W96 还差（DLinear 误差高 54%，PatchTST 高 160%）。

8.4 调小以后，短窗口在线能赢冻结长窗口吗?

怎么读（表 13）：第一轮，在线 W96 对冻结 W1024 的收益中位数，下面是在线更好的组数。

表 13　调小后，在线 W96 对冻结 W1024（第一轮）

在线 W96 对冻结 W1024	O 划分	T 划分
不调小（倍率 1，主表的做法）	+16.9% 22/31 组	−16.9% 2/30 组
调小后（验证集挑的倍率）	+33.1% 25/31 组	−7.5% 9/30 组

这一比较不在事先写好的判断线里，是结果出来后加算的。T 划分里，在线误差高出冻结的幅度缩小约一半，冻结仍占优。O 划分看起来在线赢得多，但其中一部分来自 ETTh2：那里冻结 W1024 本身比冻结 W96 还差。DLinear × PEMS08 上在线误差仍比冻结高 64%（O）和 95%（T）。另外这里只给在线调了学习率，冻结模型的学习率没动，对在线有利；冻结 W1024 也调参以后，同样历史下的比较见 8.8 节。

8.5 限制在线记忆，比同样长的历史

结论：同样长的历史下，冻结 W1024 总体更好（判断线“不差于冻结”不成立）；限制记忆确实比不限记忆差（判断线“明显更差”成立）。但这组用的是没调小的学习率；用小学习率重做的结果见 8.8 节，冻结 W1024 仍然更好。

怎么做：在线 W96 的记忆上限设成 1,024 步：两个副本错开交替重启，每 832 步回到训练好的检查点，每个时刻用重启更久的那个副本预测。这样在线模型部署后用过的最早观测离当前不超过 1,024 步（离线训练用过的更早数据不算），每个测试时刻都能和冻结 W1024 比，解决了对照 3 只能覆盖一小段的问题。学习率用倍率 1，和主表一致。

怎么读（表 14）：每格是限制记忆的在线 W96 对参照的收益中位数（正数表示限制记忆的在线误差更低），下面是在线更好的组数。

表 14　限制记忆的在线 W96（第一轮，倍率 1）

记忆上限 1,024 步的在线 W96	O 划分	T 划分
对不限记忆的在线 W96	−8.0% 1/34 组	−4.9% 10/34 组
对冻结 W1024	+9.5% 18/34 组	−21.5% 6/34 组
其中 ETTh2	+59.6% 11/11 组	+0.8% 6/11 组
其中 ETTm1	−10.1% 1/11 组	−30.8% 0/11 组
其中 Weather	+22.8% 6/6 组	−21.7% 0/6 组
其中 PEMS08	−156.2% 0/6 组	−154.0% 0/6 组

- **全部组上：**对冻结 W1024，限制记忆的在线误差高 13.1%（68 组里 24 组在线更好）；对不限记忆的在线，误差高 5.9%（68 组里 11 组更好）。
- **两处要小心：**这组用的是倍率 1，8.1 节说明它偏大，所以可能低估了在线。和不限记忆相比，它同时还取消了验证期预热，所以那 −5.9% 不能全算到“记忆更长”上。

8.6 冻结模型也认真调参以后，长窗口加更新还有好处吗？（第三轮）

结论：还有，但很小。冻结 W1024 也在验证集上选学习率、早停以后，从它出发的在线 W1024 误差在 O 划分低 3.7%、T 划分低 0.7%，按事先写好的判断线，两种划分都算“不比冻结差”。ETTh2、Electricity 的 O 划分例外。

为什么做：前两轮只调了在线学习率，冻结模型用的是主表的训练方式（所有窗口共用一个学习率、训满 50 轮、取最后一轮），对在线有利。

怎么做：DLinear 跑 7 个数据集（ETTh2、ETTm1、Weather、Solar、PEMS08、Electricity、PEMS-BAY），PatchTST 跑 ETTh2、ETTm1；W1024，H = 96，O、T 两种划分，3 个种子。冻结模型重新训练：离线学习率从 1e-5、3e-5、1e-4、3e-4、1e-3 五档里用种子 2024 在验证集上选，最多训 50 轮，验证误差连续 5 轮不降就停，取验证误差最低的一轮。在线模型（ER、PROCEED）从同一种子的调参后冻结出发，倍率从 0.003、0.01、0.03、0.1、0.3、1 六档里在验证集上挑（验证期前一半预热、后一半打分），挑定后三个种子共用。所有选择都在看测试集之前定好。判断线（事先写好）：在线对冻结的中位数 ≥ 0 算“冻结调好后，加更新仍不比不更新差”，≤ 约 −5% 算“加更新仍更差”，中间不下结论。

怎么读（表 15）：前两列是在线 W1024 对调参后的冻结 W1024 的收益中位数（正数表示在线误差更低），下面是在线更好的组数；后两列是调参后的冻结对主表的冻结（正数表示调参后误差更低），看调参让冻结模型本身好了多少。ETTh2、ETTm1 有两个骨干，组数是其他数据集的两倍。

表 15　冻结也调参后：在线 W1024 对调参后的冻结 W1024（第三轮）

数据集（变量数）	在线对调参后的冻结 · O 划分	在线对调参后的冻结 · T 划分	调参后的冻结对主表的冻结 · O 划分	调参后的冻结对主表的冻结 · T 划分
ETTh2（7）	−31.6% 0/12 组	+2.3% 7/12 组	+28.0% 6/6 组	+6.3% 6/6 组
ETTm1（7）	+7.4% 12/12 组	+1.8% 10/12 组	+20.8% 6/6 组	+7.8% 3/6 组
Weather（21）	+28.6% 6/6 组	+1.2% 6/6 组	+22.1% 2/3 组	0.0% 2/3 组
Solar（137）	+2.9% 6/6 组	+0.3% 6/6 组	+0.2% 2/3 组	+0.3% 2/3 组
PEMS08（170）	+27.5% 6/6 组	+0.6% 3/6 组	−2.5% 0/3 组	−2.1% 0/3 组
Electricity（321）	−15.2% 3/6 组	+0.6% 6/6 组	−18.9% 1/3 组	−0.3% 0/3 组
PEMS-BAY（325）	+9.1% 6/6 组	+0.6% 6/6 组	−0.3% 1/3 组	+0.1% 3/3 组
全部 7 个	+3.7% 39/54 组	+0.7% 44/54 组	+1.3% 18/27 组	0.0% 16/27 组

- **合起来：**O 划分在线误差低 3.7%（54 组里 39 组在线更好），T 划分低 0.7%（54 组里 44 组）。两种划分都过了判断线。误差超过冻结 10 倍的在线运行：108 条里 0 条。
- **调参对冻结模型本身的帮助，合起来不大，个别数据集很大：**O 划分误差低 1.3%，T 划分没变（0.0%）；但 ETTh2、ETTm1、Weather 的 O 划分分别低 28.0%、20.8%、22.1%。Electricity 的 O 划分反而高 18.9%：验证集上选出的学习率和轮数，到测试期不好用。
- **例外是 ETTh2、Electricity 的 O 划分**（在线误差高 31.6%、15.2%）。ETTh2 的损失主要来自验证期预热：预热后的冻结副本比调参后的冻结误差高 39.8%（12 组全部变差），测试期更新只追回 12.6%。Electricity 的预热让误差高 67.7%，原因见 8.11 节。
- **拆成两段（拆法同 8.2 节）：**测试期更新在 O 划分让误差低 9.8%（54 组里 51 组变好），T 划分低 0.3%；预热合起来几乎为 0（O 划分 0.0%，T 划分低 0.3%），但数据集之间差别很大：Weather 的 O 划分靠预热好了 26.1%，ETTh2、Electricity 的 O 划分被预热拖累。
- **在线也从更好的起点受益：**和前两轮的在线（从主表的冻结出发）比，误差在 O 划分低 1.3%、T 划分低 1.8%。
- **挑中的设置：**最小的倍率 0.003 在 36 个配置里被挑了 23 个；离线学习率 1e-4 被挑得最多（18 次选择里 8 次）。最小档被挑得最多，说明再小一些也许更好，这次没有再往下试。

8.7 O 划分为什么好得多：把冻结模型重训到最近（第四轮）

结论：主要是因为 O 划分的冻结模型只用了最早 20% 的数据。用前 75% 的数据重训一次冻结模型，它在最后 20% 上比一路更新的在线还好：在线误差高 8.0%，54 组里 42 组冻结更好。按事先写好的判断线，支持“新数据能解释在线的优势”。

为什么做：8.2 节猜测，O 划分对在线有利，是因为冻结模型只用前 20% 训练，见过的数据少、越往后越旧，而在线模型一路用新数据更新。检验办法是让冻结模型也用上新数据。

怎么做：第三轮的 9 组骨干 × 数据集，只做 O 划分，W1024，H = 96，3 个种子。冻结模型重新训练一次：序列前 75% 当训练集（用上所有放得下 1,024 步输入和 96 步目标的窗口），75%–80% 当验证集决定训练轮数（最多 50 轮，连续 5 轮不降就停），学习率沿用第三轮选出的，测试期不更新，叫“重训的冻结”。只在最后 20% 上评分。为了和原来的误差直接比，标准化仍用 O 划分前 20% 的均值和标准差。对照是第三轮的在线 W1024（从调参后的冻结出发，验证期预热，之后在整个 O 测试期一直更新）和调参后的冻结，都只取最后 20% 里同样的预测时刻。判断线（事先写好）：在线对重训的冻结，收益中位数 ≤ 0（在线不比它好）算“新数据能解释在线的优势”；≥ 约 +5% 算“在线还有新数据解释不了的好处”；中间不下结论。

怎么读（表 16）：都是 O 划分、只看最后 20%。前两列是在线对两种冻结的收益（正数表示在线误差更低），第三列是重训的冻结对调参后的冻结（正数表示重训后误差更低）。

表 16　重训的冻结：O 划分最后 20%（第四轮）

数据集（变量数）	在线对重训的冻结	在线对调参后的冻结	重训的冻结对调参后的冻结
ETTh2（7）	−8.4% 3/12 组	−0.7% 5/12 组	+5.6% 3/6 组
ETTm1（7）	−9.7% 0/12 组	+11.9% 12/12 组	+18.9% 6/6 组
Weather（21）	−2.3% 1/6 组	+15.3% 6/6 组	+18.7% 3/3 组
Solar（137）	−7.6% 0/6 组	+0.4% 6/6 组	+7.3% 3/3 组
PEMS08（170）	−15.5% 0/6 组	+30.7% 6/6 组	+39.5% 3/3 组
Electricity（321）	−38.2% 2/6 组	−5.6% 3/6 组	+33.1% 3/3 组
PEMS-BAY（325）	+1.1% 6/6 组	+16.2% 6/6 组	+15.3% 3/3 组
全部 7 个	−8.0% 12/54 组	+11.5% 44/54 组	+16.5% 24/27 组

- **在线对重训的冻结：**在线误差高 8.0%，54 组里只有 12 组在线更好，判断线成立。7 个数据集里 6 个是重训的冻结更好，Electricity 差得最多（在线误差高 38.2%）。PEMS-BAY 例外：在线误差低 1.1%，6 组都是在线更好。
- **同一段时间上，在线对调参后的冻结误差低 11.5%**（54 组里 44 组），这就是 O 划分在线的优势。重训以后，冻结模型的误差比调参后的冻结低 16.5%（27 组里 24 组），比在线的优势还大。

- **读法：**O 划分在线赢冻结，主要是因为冻结模型的训练数据又旧又少，用上新数据重训一次就能追上。这和 T 划分的结果对得上：T 划分的冻结模型本来就用了 60%–70% 的数据，在线几乎没有优势（表 2、表 15）。
- **要小心：**只在 75% 处重训了一次，重训一次的计算量相当于从头训练一个模型；没有比在同样计算量下，定期重训和在线更新哪个更好。只做了 W1024、H = 96、O 划分。实际部署时会用新数据重新算标准化，这里为了可比没有这样做。

8.8 同样长的历史，换成小学习率再比（第四轮）

结论：结果取决于冻结模型有没有调参。把在线 W96 的记忆限制在 1,024 步、用小学习率：对调参后的冻结 W1024，在线误差在 O 划分高 11.4%、T 划分高 12.2%（T 划分 36 组全是冻结更好）；对主表的冻结，O 划分在线反而低 22.0%（主要来自 ETTh2 和 Weather，那两处主表的冻结 W1024 没训好），T 划分高 8.9%。在线一方的离线训练没调参，这对冻结有利。限制记忆只让误差高 1%–3%。

为什么做：8.5 节第一次比“同样长的历史”，但有两个问题：在线用的是倍率 1（8.1 节说明它偏大）；限制记忆的在线不预热、不限记忆的在线预热，两者的差别不全是记忆长短。

怎么做：DLinear 跑 ETTh2、ETTm1、Weather、PEMS08，PatchTST 跑 ETTh2、ETTm1；O、T 两种划分，ER、PROCEED，W96，H = 96，3 个种子。两种在线各 72 条运行：限制记忆（同 8.5 节：两个副本错开交替重启，每 832 步回到训练好的检查点，部署后用过的最早数据离当前不超过 1,024 步）和不限记忆（一个副本一直更新）。两种都从主表训练好的 W96 模型出发，都不预热；倍率用第一轮在验证集上为 W96 挑中的。冻结 W1024 有两个参照：主表的冻结和第三轮调参后的冻结。注意在线一方的离线训练没调参，调参后的冻结却在验证集上选过学习率、早停过。判断线（事先写好，但没指定用哪个冻结）：限制记忆的在线对冻结 W1024 的中位数 $\geqslant 0$，算“同样长的历史下在线不比冻结差”；限制记忆对不限记忆的对数误差比中位数 $\leqslant -0.03$（误差高约 3% 以上），算“记忆更长确实有用”。

怎么读（表 17）：行的排法和表 14 一样，方便对照。每格是限制记忆的在线 W96 对参照的收益中位数（正数表示限制记忆的在线误差更低），下面是它更好的组数。

表 17　限制记忆的在线 W96，小学习率（第四轮）

记忆上限 1,024 步的在线 W96（小学习率）	O 划分	T 划分
对不限记忆的在线 W96（两边都不预热）	−3.0% 6/36 组	−1.3% 6/36 组
对主表的冻结 W1024	+22.0% 24/36 组	−8.9% 13/36 组
其中 ETTh2	+53.0% 12/12 组	+4.0% 12/12 组
其中 ETTm1	−0.8% 6/12 组	−8.9% 1/12 组
其中 Weather	+25.0% 6/6 组	−18.7% 0/6 组
其中 PEMS08	−69.3% 0/6 组	−115.0% 0/6 组
对调参后的冻结 W1024（第三轮）	−11.4% 16/36 组	−12.2% 0/36 组
其中 ETTh2	+33.8% 12/12 组	−2.6% 0/12 组
其中 ETTm1	−15.5% 0/12 组	−13.1% 0/12 组
其中 Weather	+3.8% 4/6 组	−17.8% 0/6 组
其中 PEMS08	−64.8% 0/6 组	−110.7% 0/6 组

- **对调参后的冻结 W1024：**在线误差 O 划分高 11.4%（36 组里 16 组在线更好），T 划分高 12.2%（0/36）。判断线“同样长的历史下在线不比冻结差”：按调参后的冻结算，两种划分都不成立；按主表的冻结算，O 划分成立、T 划分不成立（下一条）。只有 ETTh2 的 O 划分在线明显更好（误差低 33.8%）。
- **对主表的冻结 W1024：**O 划分在线误差低 22.0%（36 组里 24 组），T 划分高 8.9%（13/36）。O 划分的“赢”主要来自 ETTh2（低 53.0%）和 Weather（低 25.0%）；这两处主表的冻结 W1024 训得不好，调参后分别好了 28.0%、22.1%（表 15）。PEMS08 两种划分在线都差得多（误差高 69.3%、115.0%）。
- **和表 14 比：**表 14 用倍率 1。学习率调小后，对主表的冻结，O 划分从低 9.5% 变成低 22.0%，T 划分从高 21.5% 变成高 8.9%，对在线有利得多，但对调参后的冻结仍然输。
- **记忆上限的作用：**限制记忆对不限记忆（这次两边都不预热），O 划分误差高 3.0%（对数比 −0.029，差一点没到 −0.03 的判断线），T 划分高 1.3%；36 组里各只有 6 组限制记忆更好。超过 1,024 步的“记忆”有一点用，但不多。
- **预热的作用：**不限记忆、不预热的在线，对第一轮预热过的同一设置，误差在 O 划分高 0.4%、T 划分高 1.4%：预热在 W96 上作用很小。

- **读法和要小心：**冻结 W1024 调过参以后，同样 1,024 步的历史，当输入读的冻结模型更好。但在线一方的离线训练没调参（从主表的 W96 出发），这对冻结有利；两边都用主表的训练方式时，O 划分是在线更好。要分出哪种用历史的方式更有效，需要两边都调参再比。

8.9 PEMS-BAY 上的训崩，也是学习率太大吗？（第四轮）

结论：是。PatchTST × PEMS-BAY 的短窗口在线，倍率 1 时 12 条运行里 3 条误差超过冻结 W96 的 10 倍，调小后一条都没有。但调小后在线仍比不更新差：误差比冻结 W96 高 43.8%（O）和 27.5%（T），12 条全是冻结更好。

怎么做：PatchTST × PEMS-BAY，W96，H = 96，Naive、PROCEED 两种在线方法，O、T 两种划分，3 个种子。倍率从 0.03、0.1、0.3、1 里用种子 2024 在验证集上挑，4 个配置都挑了最小的 0.03。倍率 1 的结果用主表的。参照是同样读 96 步、但不更新的冻结 W96。

怎么读（表 18）：前三行是收益中位数（正数表示前者误差更低），下面是前者更好的组数；最后一行是误差超过冻结 W96 10 倍的条数。

表 18　PatchTST · PEMS-BAY 的短窗口在线（第四轮）

PatchTST · PEMS-BAY · 在线 W96	O 划分	T 划分
不调小（倍率 1，主表的做法）对冻结 W96	−339.4% 0/6 组	−244.7% 0/6 组
调小后（倍率 0.03）对冻结 W96	−43.8% 0/6 组	−27.5% 0/6 组
调小后对不调小	+67.3% 6/6 组	+63.1% 6/6 组
误差超过冻结 W96 10 倍的条数（不调小 → 调小后）	1/6 → 0/6	2/6 → 0/6

- **训崩没了：**倍率 1 时误差超过冻结 10 倍的有 3 条（O 划分 1 条、T 划分 2 条），调小后 0 条。按事先写好的读法，支持“原来的极端误差主要来自过大的学习率”。
- **但还是比不更新差：**调小后对倍率 1，误差低 67.3%（O）和 63.1%（T），12 条全部变好；可对冻结 W96 仍高 43.8% 和 27.5%。倍率 1 时是高 339% 和 245%（误差是冻结的 4.4 倍、3.4 倍）。
- 和 8.1 节 PEMS08 的结果一样：小学习率能防止训崩，但 PatchTST 在这两个变量多的交通数据集上，短窗口在线仍比不更新差。

8.10 预测 336 步（第四轮）

结论：方向和预测 96 步时一样，在线更吃亏一点。调小学习率后，在线 W1024 对冻结 W1024，O 划分误差低 1.3%（按判断线算“不比冻结差”），T 划分高 3.1%（落在中间，不下结论）；T 划分 7 个数据集里有 6 个每条运行都是冻结更好。不调小时在线误差高约 30%。

怎么做：DLinear 跑第三轮的 7 个数据集，W1024，H = 336，O、T 两种划分，ER、PROCEED，3 个种子。倍率从 0.03、0.1、0.3、1 里用种子 2024 在验证集上挑：28 个配置里 21 个挑了 0.03，3 个挑了 1（ETTh2 · O · ER、ETTm1 · O · PROCEED、PEMS08 · O · ER）。冻结 W1024 用主表的，没有重新调参；倍率 1 的在线用 11 月 1 日前跑完、保留下来的那批运行，缺的按规则补跑。判断线同 8.1 节。

怎么读（表 19）：前两列是调小后的在线 W1024 对冻结 W1024，后两列是不调小（倍率 1）的在线对冻结 W1024；正数表示在线误差更低，下面是在线更好的组数。

表 19　预测 336 步：在线 W1024 对冻结 W1024（第四轮，只有 DLinear）

数据集（变量数）	调小后 · O 划分	调小后 · T 划分	不调小 · O 划分	不调小 · T 划分
ETTh2（7）	−530.6% 0/6 组	+24.5% 6/6 组	−736.5% 0/6 组	+9.7% 5/6 组
ETTm1（7）	−18.8% 0/6 组	−1.8% 0/6 组	−59.5% 0/6 组	−49.8% 0/6 组
Weather（21）	+25.7% 6/6 组	−9.6% 0/6 组	+10.9% 6/6 组	−46.1% 0/6 组
Solar（137）	+1.8% 6/6 组	−21.8% 0/6 组	−22.0% 0/6 组	−53.4% 0/6 组
PEMS08（170）	+18.0% 6/6 组	−6.3% 0/6 组	+16.4% 3/6 组	−47.5% 0/6 组
Electricity（321）	−109.3% 0/6 组	−2.3% 0/6 组	−372.1% 0/6 组	−17.6% 0/6 组
PEMS-BAY（325）	+9.3% 6/6 组	−3.0% 0/6 组	−24.9% 0/6 组	−34.9% 0/6 组
全部 7 个	+1.3% 24/42 组	−3.1% 6/42 组	−27.2% 9/42 组	−31.4% 5/42 组

- **合起来：**调小后，O 划分在线误差低 1.3%（42 组里 24 组在线更好），T 划分高 3.1%（42 组里 6 组）。不调小时分别高 27.2%、31.4%。调小后对不调小，误差低 21.2%（84 组里 73 组变好，另有 9 组挑中的就是倍率 1，结果相同）。
- **T 划分：**除 ETTh2（在线误差低 24.5%）外，6 个数据集每条运行都是冻结更好，Solar 差得最多（在线误差高 21.8%），Weather 高 9.6%。预测 96 步时（表 9），这 6 个数据集的 T 划分都在 ±2% 以内。猜测：预测 336 步时，一个预测要等 336 步后真实值到齐才能拿来更新，数据变了以后，在线模型要更久才能跟上。
- **O 划分：**ETTh2 在线误差高 531%（6 组全是冻结更好；ER 挑中的是倍率 1，这 3 条误差超过冻结 10 倍），Electricity 高 109%，ETTm1 高 18.8%；其余 4 个在线更好（Weather 低 25.7%、PEMS08 低 18.0%）。ETTh2 的 O 划分训练段只有 2,880 步，放下 1,024 步输入和 336 步目标后能用的训练样本很少，两边的误差都很大（冻结的 MSE 在 22–24 之间，标准化尺度）。
- **要小心：**这里只给在线调了倍率，冻结用的是主表的、没调参，对在线有利；只有 DLinear。

8.11 Electricity 的 O 划分为什么是例外（第三轮的诊断）

结论：一部分是数据的问题，但不全是。Electricity 有一个变量在 O 划分的训练段里几乎不变，标准化后它的误差被放大，占了主表冻结模型测试误差的 98%，预热造成的损失也几乎全在它身上。可在其余 320 个变量上，不预热、只在测试期更新的在线模型，误差也比冻结高 28%–55%。去掉这个变量重跑的实验（实验 E）已安排，结果还没回来。

怎么查：只看 DLinear · Electricity · O · 种子 2024，用第二轮挑中的倍率（ER 0.1、PROCEED 0.03）。① 算训练段（前 20%，5,260 步）里每个变量的标准差，找出不到全体中位数 1% 的变量；② 把第二轮的预热原样重放一遍，得到预热后的冻结副本，按变量拆开它在测试期的误差；③ 另跑一条不预热的在线：从主表的冻结 W1024 出发，只在测试期更新。

怎么读（表 20）：每格是对主表冻结 W1024 的收益（正数表示误差更低）；左列算全部 321 个变量，右列去掉编号 146 的变量、只算其余 320 个。每格只有一条运行。

表 20　Electricity · O：去掉一个几乎不变的变量前后（第三轮诊断）

对主表的冻结 W1024（DLinear · Electricity · O · 种子 2024）	全部 321 个变量	去掉编号 146，其余 320 个
预热后的冻结副本 · ER（倍率 0.1）	−165.5%	−1.2%
预热后的冻结副本 · PROCEED（倍率 0.03）	−220.6%	−6.1%
不预热的在线 · ER（倍率 0.1）	−60.6%	−55.2%
不预热的在线 · PROCEED（倍率 0.03）	−20.1%	−28.3%

- **编号 146 的变量**（数据里的列名就是 146）：训练段标准差只有 0.91，全体变量的中位数是 207.9（它约为中位数的 0.4%），321 个变量里只有它低于 1%。标准化要除以这个标准差，测试期它只要稍有变化，标准化后的数值就很大。主表冻结模型在测试期的 MSE 是 9.14，去掉这一个变量只有 0.18：98.1% 的平方误差来自它。至少在这条运行上，Electricity · O 的误差几乎就是这一个变量的误差。
- **预热：**预热后的冻结副本，在全部变量上误差是主表冻结的 2.66 倍（ER）和 3.21 倍（PROCEED），误差增加的部分 99.9% 以上在这个变量上。只看其余 320 个变量，预热只让误差高 1.2%（ER）和 6.1%（PROCEED）。
- **测试期更新：**不预热的在线，在全部变量上误差比主表冻结高 60.6%（ER）和 20.1%（PROCEED）；只看其余 320 个变量也高 55.2% 和 28.3%。也就是说，其余 320 个变量合起来，测试期更新也让误差变高（只有一条运行，看不出是多数变量变差还是少数变量差得多），不能全怪编号 146 的变量。表 11 里 Electricity 的 ② 是 +51%，那是和已被预热拖坏的副本比，和这里不矛盾。
- **猜测：**在线更新的损失把所有变量的误差加在一起，编号 146 的变量占了绝大部分，参数主要朝着减小它的误差去调；如果各变量共用参数，其余 320 个变量就会被带偏。
- **实验 E（已安排，结果还没回来）：**E1 扫一遍 10 个数据集、两种划分，看还有没有别的几乎不变的变量；E2 去掉编号 146 的变量（输入、损失、评分都不用它），按第三轮的做法重跑 Electricity · O；E3 同样去掉它，按主表的做法重跑冻结 W1024 和在线 W96，和主表同一格比。

读这些结果时要记住：窗口只有 W96 和 W1024；预测长度大多是 96，只有 8.10 节是 336；数据集最多 7 个（第一轮 6 组骨干 × 数据集、第二轮 4 组、第三轮 9 组）。第一、二轮只调了在线学习率，冻结模型用的是主表的训练方式；第三轮给冻结 W1024 也调了参，合起来只好了 1.3%（O）和 0.0%（T），和主实验里另一套“调参轨道”的结果（ETT、Weather 上每个窗口单独选学习率并早停，冻结 W1024 单独调能再好 1%–2%）同一量级，但个别数据集差别很大（表 15）。中位数和重抽样区间只作描述，不是严格的统计检验；学习率为什么重要、O 划分为什么有利，都还有猜测的成分。还在等的：Electricity 去掉编号 146 的变量重跑（实验 E，已安排，结果还没回来）。

第 9 节 · 结论

现在能说什么，还不能说什么

能说 在这次的训练预算和覆盖范围内

- 短窗口在线学习总体上没有打败长窗口冻结模型。
- 传统划分下，15 个中位数比较全部是冻结更好（表 2）；其中对 W512–W1024 的 9 个，按数据集重抽样也稳定是冻结更好，10 个数据集里在线更好的最多 1 个。
- 在线式划分下有输有赢（表 1）：对 W512、W720 在线输；对 W1024、W2048，ER、PROCEED 与冻结基本打平；对 W4096 在线赢，但主要因为这一档冻结模型本身变差。按数据集重抽样，这些输赢都不稳。按数据集看（表 5，只看 ER 对 W1024 这个切片），ETT 四个和北京（都是 7 个变量）大多偏向在线，Weather、Solar、PEMS08、Electricity、PEMS-BAY（21–325 个变量）都偏向冻结。
- 继续更新在部分运行里能让误差低几个百分点，但个别运行会训崩，误差大到离谱（图 2）。
- 在线模型离线训练更省，部署时每次预测的用时是冻结模型的 3–7 倍（图 4）。
- 在线学习率影响很大（第 8 节表 7–9，前两轮，H = 96）：调小后，长窗口模型加更新基本不再比不更新差，7 个数据集合起来，在线误差比冻结在 O 划分低 7.4%、在 T 划分高 0.7%；Electricity 的 O 划分例外。PEMS08 上误差超过冻结 10 倍的运行也没有了，PEMS-BAY 上也一样（表 18）。
- 冻结模型也认真调参后（第三轮），长窗口模型加小学习率的更新仍不比不更新差：在线 W1024 的误差比调参后的冻结 W1024 在 O 划分低 3.7%、T 划分低 0.7%（表 15）；ETTh2、Electricity 的 O 划分例外。
- O 划分比 T 划分对在线有利，不是因为测的时间段不同（只看每条序列最后约 20%，O 划分仍比 T 划分对在线有利得多：长窗口在线误差低 13%、T 划分打平（表 11）；主表的短窗口在线对冻结 W1024 是 ER 0.0%、PROCEED −1.0%，T 划分是 −24.7%、−23.3%），而是因为 O 划分的冻结模型只用了最早 20% 的数据：用前 75% 重训一次，冻结模型在最后 20% 上反而比在线好，在线误差高 8.0%（表 16）。

还不能说 现有数据撑不住的

- 在线的好处是不是都能靠重训拿到、哪个更划算。重训只在 O 划分、W1024、H = 96 上做了一次（在 75% 处），PEMS-BAY 上在线仍略好；没有比同样计算量下定期重训和在线更新的成本。
- 各方法都调到最优以后的排名。第三轮只给冻结 W1024 和从它出发的在线调了参；主表的其他窗口、短窗口在线 W96 的离线学习率，还是所有窗口共用一个。
- 在线更新的步子多小才合适。第三轮加了 0.01、0.003，最小的 0.003 在 36 个配置里被挑了 23 个，再小会怎样还没试。
- Electricity 的 O 划分为什么例外。第三轮的诊断指向一个几乎不变的变量，但其余 320 个变量上在线也更差（8.11 节）；去掉它重跑的实验 E 已安排，结果还没回来。
- 同样长的历史下，当输入读和靠更新记进参数哪个更有效。表 17 里在线一方的离线训练没调参，两边都调参的比较还没做。
- 别的预测长度和骨干。预测 24 步没做补充实验；预测 336 步只做了 DLinear。
- 严格的统计显著性。按数据集重抽样只是粗略估计：数据集只有 7–10 个；同一数据集上的配对共用同一段测试数据，彼此相关；每次运行内部，相邻时刻的预测区间也互相重叠。

- 同样 1,024 步的历史下，调参后的冻结 W1024 比记忆限制在 1,024 步的在线 W96 误差低：在线误差高 11.4%（O）、12.2%（T，36 组全是冻结更好）（表 17）。但在线一方的离线训练没调参；两边都用主表的训练方式时，O 划分是在线好 22.0%。
- 预测 336 步时（只有 DLinear，表 19），调小学习率的在线 W1024 对冻结 W1024：O 划分在线误差低 1.3%，T 划分高 3.1%，方向和预测 96 步一样，在线更吃亏一点。

第 10 节 · 讨论

想一起讨论的几个问题

每个预测时刻的误差记录都保留着，问题 3、4 用现有结果还能继续分析；问题 2、4、5、6 在第 8 节的补充实验里有了新结果。

1 **我们想讲哪种结论？**
实用结论（固定预算下选哪种部署方式）有数据支持。机制结论（是历史在起作用还是更新在起作用），第三、四轮给了更多证据（见问题 5、6），但范围还窄：最多 7 个数据集，大多是 W1024、H = 96。

2 **个别运行误差暴涨是怎么回事？和学习率有关吗？**
是个别在线运行“训崩”了：更新时参数跑飞，之后的预测误差大到离谱。主表 1,079 条短窗口在线运行里，有 16 条的 MSE 超过冻结模型的 10 倍，全是 PatchTST：多数是 PROCEED 在 PEMS-BAY、PEMS08 上，另有 5 条 Naive 在 PEMS08 上。最极端的一条是 PEMS-BAY · PatchTST · PROCEED · T 划分 · H = 96 · 种子 2025：在线 MSE 1.13×10^{11}，同一配置的冻结只有 0.55。这一条就占了“PROCEED 对 W512（T 划分）收益均值 -1.2×10^{11}%”的 99.7%；O 划分那个 −2,595% 的均值，95% 来自 PEMS08 · PatchTST 的三个种子。所以全页用中位数，均值只当提醒。和学习率有关：补充实验把在线学习率调小后，PEMS08 上原来 10 条误差超过冻结 10 倍的运行一条都没有了（最大从约 37,693 倍降到 3.2 倍，见 8.1 节）。第四轮在 PEMS-BAY 上也验证了（8.9 节、表 18）：PatchTST 不调小时 12 条里 3 条误差超过冻结 W96 的 10 倍，调小后一条都没有；但这 12 条仍都比冻结 W96 差（中位数高 28%–44%）。

3 **W4096 的“赢”主要是哪个原因？（部分已核对）**
只用同时有 W4096 的 87 组配对重读：在线对 W2048 的收益是 −7.5% 到 +4.9%（基本打平），对 W4096 是 +17.0% 到 +32.1%（在线误差低 17%–32%）；同一批配对上，冻结 W4096 的 MSE 是 W2048 的 1.24 倍。所以主要是冻结 W4096 本身变差，数据集变少只解释了一小部分；为什么变差（样本少、参数多、不早停）还是推测。按数据集重抽样，对 W4096 这三格的 95% 区间也都略跨过 0。另一组现成结果（ETT、Weather 上每个窗口单独选学习率并早停）里，冻结 W4096 在 T 划分上能好 16%，也说明它在主表的训练方式下没训好。详见第 3 节和表 3。

4 **变量多的数据集在线全输，是因为变量多吗？**

主表 ER 对 W1024 这个切片里（表 5），7 个变量的数据集（ETTh1、ETTh2、ETTm1、ETTm2、北京）在 O 划分的 10 格里，在线赢 9 格；变量更多的五个数据集（Weather 21 个、Solar 137 个、PEMS08 170 个、Electricity 321 个、PEMS-BAY 325 个）有数据的 8 格，在线全输。别的切片是不是也这样，还没查。这五个同时也是气象、光伏、交通、电力数据，“变量多”也可能只是数据类型不同的代理。可能的原因：变量多时每次更新的幅度、共用的学习率、缺测和零值的处理方式。补充实验里，长窗口在线（表 9，在线 W1024 对冻结 W1024）：学习率调小后，这五个数据集合起来，O 划分在线误差低 7.4%（Electricity 除外），T 划分高 1.3%；ETTh2、ETTm1（7 个变量）上 T 划分在线误差低 3.8%。短窗口在线（W96）调小学习率后，第一轮在 Weather、PEMS08 上和冻结 W1024 比过（DLinear）：Weather 的 O 划分在线误差低 27%、T 划分高 11%；PEMS08 高 64%（O）和 94%（T）。第四轮的 PEMS-BAY（PatchTST，只能和冻结 W96 比）仍高 44%（O）和 28%（T）（表 18）。另外，Electricity 的 O 划分有一个几乎不变的变量，冻结模型测试误差的 98% 来自它（8.11 节）；主表这一格去掉它以后怎样，实验 E 会看。

5 **O 和 T 结论不同，是训练量、测试时间段还是测试期长度在起作用？（已有结果）**

两种划分同时改变了训练量、时间段和测试期长度。时间段这一条已经可以排除：O 划分的测试期占整条序列的后 75%，切成 10 段后，最后 3 段大约就是序列的最后 22.5%，和 T 划分的测试期（最后 20%）差不多是同一段时间。只在这一段上比，主表里在线对冻结 W1024 的收益是 ER 0.0%、PROCEED −1.0%、Naive −13.7%，仍远好于 T 划分的 −24.7%、−23.3%、−41.5%；补充实验的长窗口在线也一样（表 11：这一段上 O 划分在线误差低 13%，T 划分打平）。所以更可能是训练量和新旧：O 划分的冻结模型只见过前 20% 的数据，越往后越旧。第四轮做了检验（8.7 节、表 16）：用前 75% 重训一次冻结模型，在最后 20% 上，一路更新的在线误差反而比它高 8.0%（54 组里 42 组冻结更好）。T 划分的冻结模型本来就用了 60%–70% 的数据，所以在线在 T 划分没什么可补的。测试期长度这一条还没单独分开。

6 **怎么把“历史”和“更新”分开？（已有结果）**

2×2 和限制记忆在第 8.3、8.5 节（表 12、表 14）：学习率调小后，更新和长窗口的好处大致叠加；同样长的历史下，学习率没调小的在线模型总体输给冻结 W1024（在线误差高 13%）。第三、四轮又补了三点：① 换成小学习率以后，同样 1,024 步的历史，调参后的冻结 W1024 仍比限制记忆的在线 W96 好，在线误差高 11.4%（O）和 12.2%（T）；但在线一方的离线训练没调参，对主表的冻结，O 划分是在线好 22.0%（8.8 节、表 17）；② 在长窗口模型上再加小学习率的更新，还能好一点：O 划分误差低 3.7%，T 划分低 0.7%（8.6 节、表 15）；③ 超过 1,024 步的记忆作用不大：限制记忆只让误差高 1%–3%（表 17）。读法：更新在长窗口上有小幅好处，而在 O 划分，在线的优势重训一次冻结模型也能拿到（8.7 节）；同样长的历史下，当输入读和靠更新记进参数哪个更有效，要两边都调参再比。可能的后续（都还没安排）：

- 同样长的历史下两边都调参再比：在线 W96 的离线训练也在验证集上选学习率、早停，再和调参后的冻结 W1024 比。
- 定期重训和在线更新比成本：同样的计算量下，每隔多久重训一次冻结模型能追上在线。
- 倍率再往下试（0.003 在第三轮被挑得最多）。
- 每个窗口、每个方法分别调学习率（推迟的调参方案），只在需要给方法排名时再做。

第 11 节 · 附录

背景与参考

▼ **前一轮研究：用过去的误差修正冻结模型的预测（10 月 25–27 日）**

2,160 组运行：12 个模型 × 10 个数据集 × 3 种输入长度 × H = 4、24 × 3 个种子。问题是：输入变长能不能消掉误差里的周期结构？固定的周期模板、近期误差还能修正多少？这一轮没有测试在线更新参数，和主实验分开报告。数据集和主实验不完全相同（有 Traffic、Illness），表里的“收益”是各行自己的对比（比如长输入对短输入），不是本页的在线对冻结。它只是背景：更长的输入有时有用、有时没用。

表 21　前一轮研究的主要结果

输入变长	同一个模型，长输入对短输入：Electricity 和 Traffic 各 72 组配对全部变好（MSE 收益中位数 +25.85%、+28.35%），但全部 720 组配对里只有 365 组变好，所以输入变长并不总有用。
固定周期模板	在验证集上拟合、用到测试集：1,944 组里只有 393 组变好，收益中位数 −2.32%。
再加近期误差	在模板之外的额外收益中位数约 +0.01%；MixLinear 是局部例外。
误差形状	2,160 组里有 1,701 组，预测窗口的均值偏移占了总 MSE 的一半以上。但有偏移不等于这个偏移能被预测。
Illness	216 组数据太短、不够校准：属于无法评估，不是失败。

另有一个用测试集前 2/3 校准、后 1/3 评分的协议（2,052 组），用到了测试集，只能算探索，不能当确认。880 组训练到了 50 轮上限，590 组的最佳验证点就在第 50 轮，所以这轮结果也不是 12 个模型调优后的排名。

▼ 实验范围与 11 月 1 日的缩减

- 主实验：10 个数据集 × 2 个骨干 × 2 种划分 × 3 个预测长度 × 3 个种子。冻结窗口 6 档（W = 96、512、720、1,024、2,048、4,096），在线方法 3 种（W = 96），每种都配一个同起点的冻结副本。
- 11 月 1 日为了控制预算缩小了范围：每个窗口、每个方法分别调参的方案和长窗口在线实验推迟了（后来的补充实验做了其中一小部分：W1024 的长窗口在线、W1024 冻结的调参，见第 8 节）。这是按预算砍的，不是看了测试结果再删的；已经跑完的部分都保留。
- 受资源限制跑不了的窗口单列排除，没有为了放得下而改 batch、精度或训练轮数。

▼ 数据处理

- 标准化只在训练集上拟合；损失和评分只算真实观测到的目标值。
- 当作真实数据保留的零值：Solar 夜间、PEMS08 流量。当作缺测处理：PEMS-BAY 的零速度、Weather 的 −9999。
- 北京：Quotsoft 城市级数据里的北京（全市一组数，不是单个站点），7 个变量（AQI、PM2.5、PM10、SO2、NO2、O3、CO），2014-05-13 到 2018-06-20 共 36,000 个小时，按北京时间处理。输入只做因果的前向填充，开头的缺口用训练集均值补。其中 10 天的原始文件缺失，单独标记，不算作实测缺测。

▼ 术语表

O / T 划分	在线式（20/5/75）和传统（60–70/10–20/20）两种训练/验证/测试划分。
固定预算设置	主表和各对照用的训练方式。另有一套“每个窗口、每个方法分别选学习率并早停”的调参方案，已推迟（第三轮只给 W1024 做了一部分）。
倍率	补充实验里，在线更新的学习率 = 离线学习率 × 倍率。倍率 1 就是主表的做法：在线更新和离线训练步子一样大。

三种冻结 **W1024**	主表的冻结：主表的训练方式（所有窗口共用一个学习率、训满 50 轮、取最后一轮）。调参后的冻结：第三轮，学习率在验证集上选、早停。重训的冻结：第四轮，用序列前 75% 重新训练，只在最后 20% 上评分。
记忆上限	让在线模型部署后只“记得”最近 1,024 步（离线训练用过的数据不算）：两个副本错开交替重启，每 832 步回到训练好的检查点（第 8.5、8.8 节）。
预热	在线模型在验证期就开始边预测边更新，测试期接着更新；验证期这一段叫预热（不是学习率 warm-up）。冻结模型不预热。
同起点冻结	测试开始时从在线模型复制出来、之后不再更新的那一份（对照 2，英文 matched-frozen）。
K(t)	在线模型从验证期预热开始、到时刻 t 为止一路用过的数据跨度（训练集两边都用过，不算在内）。
同等历史比较	找窗口 W ⩾ K(t) 的最短冻结模型来比（对照 3，英文 F-cover）。
收益	(冻结误差 − 在线误差) ÷ 冻结误差 × 100%，正数表示在线更好。
配对	同一数据集、骨干、划分、预测长度、种子、在线方法下的一个在线运行和一个冻结运行，在共同的预测起点上评分，得到一个收益值。每格最多 180 组（10 × 2 × 3 × 3）。

2026 年 11 月 9 日根据已完成实验的逐配置结果整理。主表和三个对照没有新跑实验，W4096 一段的固定数据集比较和对照 3 的分数据集说明，是用这些结果重新统计的。“补充实验”一节是 11 月 5–8 日新跑的四轮，实验 E 的结果还没回来。中位数只作描述。