短窗口在线学习，能打败长窗口冻结模型吗?

比什么：在线模型只读最近 96 步，部署后用陆续到达的真实值不停更新参数（Naive、ER、PROCEED 三种方法）；冻结模型读 512–4,096 步，训练完不再改。**怎么比：**同一份代码、同一套训练预算（50 轮、不早停、所有模型共用一个学习率），10 个数据集 × DLinear、PatchTST × 预测长度 24/96/336 × 3 个种子；两种划分：传统 T（训练/验证/测试 = 60–70/10–20/20）和在线式 O（20/5/75）。

答案：总体上没有。

- **传统划分 T：**15 个比较（3 种方法 × 5 档窗口）全是冻结赢，按中位数算，在线的 MSE 高 12%–49%。
- **在线式划分 O：**对 W512、W720 在线输；对 W1024、W2048，ER、PROCEED 与冻结打平（在线误差比冻结高 2.1% 到低 1.8%）；对 W4096 在线赢（在线误差低 17%–32%），但核对后主要是冻结 W4096 本身变差：同一批配对上，它的 MSE 是 W2048 的 1.24 倍。
- **只看“继续更新”：**测试开始时把在线模型复制两份，一份继续更新、一份冻结：继续更新那份的误差比冻结那份高 5.0% 到低 4.7%（中位数），个别运行会训崩、误差大到离谱。部署时每次预测的用时是冻结模型的 3–7 倍。

表 1　O · 在线式划分 20/5/75

冻结 W	512	720	1,024	2,048	4,096
Naive	−22.8	−34.2	−12.0	−19.9	+17.0
ER	−10.3	−9.9	−2.1	−1.7	+30.8
PROCEED	−14.4	−14.6	+1.1	+1.8	+32.1

表 2　T · 传统划分 60–70/10–20/20

冻结 W	512	720	1,024	2,048	4,096
Naive	−48.0	−49.2	−41.5	−28.3	−20.1
ER	−35.7	−34.4	−24.7	−19.0	−16.5
PROCEED	−36.3	−35.0	−23.3	−15.1	−12.3

在线更好　冻结更好　相差 ±5% 以内

每格是在线模型（W = 96）相对该档冻结窗口的 MSE 收益中位数（%）：收益 = (冻结 MSE − 在线 MSE) ÷ 冻结 MSE，正数表示在线更好；最高 +100%，往下没有下限（−100% 即在线误差是冻结的 2 倍）。每格是 86–180 组配对（数据集 × 骨干 × 预测长度 × 种子）的中位数。O 划分的 W4096 只剩 7 个数据集，训练段比 4,096 步短的跑不了。

补充实验（完整版第 8 节；11 月 5–8 日四轮，大多是 W1024、H = 96；第二页有表）

- **调小在线学习率**（离线 × 0.03–1，验证集选）：长窗口在线 W1024 基本不再比冻结 W1024 差，7 个数据集合起来，O 划分在线误差低 7.4%，T 划分高 0.7%；Electricity 的 O 划分例外（原因在查）。不调小时普遍更差（第一轮同一批配置上，T 划分在线误差高 16.8%）。PatchTST 在 PEMS08、PEMS-BAY 上超过冻结 10 倍的训崩也没了，但那里短窗口在线仍比不更新差。
- **冻结也调参后：**在线 W1024 对调参后的冻结 W1024，误差在 O 划分低 3.7%、T 划分低 0.7%，仍略好。
- **为什么 O 划分好得多：**O 划分的冻结只用了最早 20% 的数据。用前 75% 重训一次，它在最后 20% 上比一路更新的在线还好（在线误差高 8.0%）。
- **同样长的历史：**在线 W96 的记忆限制在 1,024 步，对调参后的冻结 W1024，在线误差高 11%–12%；但在线一方没调参，两边都不调参时 O 划分是在线好 22%。
- **预测 336 步**方向和 96 步一样（O 划分在线误差低 1.3%，T 划分高 3.1%）。

待讨论

1. **结论定位：**实用结论（固定预算下选哪种部署方式）已有数据支持。机制上补充实验给了两点：长窗口加小学习率的更新只有小幅好处；O 划分里在线的优势，重训一次冻结模型就能拿到。这两点放主结论还是放讨论。
2. **下一步比不比成本：**同样计算量下，定期重训冻结模型和在线更新哪个更划算。
3. **发散运行怎么报告：**主表有两条在线运行的误差是冻结的上亿倍（最大约 2×10^{11} 倍），目前按中位数加发散比例报告。

注意：主表所有方法共用一个学习率；同一数据集的配对共用一段测试数据，彼此相关，没有做显著性检验。

完整版（29 页，含定义、例子、分数据集结果和补充实验）：reports/full_study/BUA_brief_full_zh.pdf

学习率调小以后，再给冻结模型同样的机会，在线还占优吗？

为什么做：主实验保留的在线 W1024 运行里，加上在线更新常常比不更新还差。前两轮把在线学习率调小（离线 × 0.03–1，验证集挑）；第三、四轮再给冻结模型同样的机会：调参、重训、看同样长的历史。最多 7 个数据集，大多是 W1024、预测 96 步。

答案：学习率调小后，长窗口加更新不再变差；但冻结重训用上新数据后，比在线还好。

- **学习率是主要原因：**第二轮能配对的 29 组，调小后在线比不调小的自己误差低 16%，对冻结从差 19% 变成好 1.6%。7 个数据集合起来，调小后在线比冻结在 O 划分误差低 7.4%，T 划分高 0.7%。
- **冻结也调参后**（学习率在验证集上选、早停），从它出发的在线 W1024 仍略好（表 15–19 第 ① 行）。
- **但冻结重训用上新数据后，比一路更新的在线好：**重训到 75% 的冻结，在最后 20% 上让在线误差高 8.0%（②）。同样 1,024 步的历史下，调好的冻结 W1024 比记忆受限的在线 W96 好（③），但在线一方没调参，两边都不调参时 O 划分是在线好。

表 9（简版） 调小学习率后，在线 W1024 对冻结 W1024

数据集（变量数）	O	T
ETTh2（7）	−1.8 6/12	+4.7 12/12
ETTm1（7）	+25.5 10/10	+1.7 9/12
Weather（21）	+44.7 6/6	−0.9 0/6
Solar（137）	+4.9 12/12	−1.5 3/12
PEMS08（170）	+22.0 6/6	−0.2 3/6
Electricity（321）	−40.3 0/6	−1.1 0/6
PEMS-BAY（325）	+8.2 6/6	−1.7 0/6
全部 7 个	+7.4 46/58	−0.7 27/60

表 15–19（只列合计） 第三、四轮的结果

在线对冻结	O	T
① 冻结也调参	+3.7 39/54	+0.7 44/54
② 重训的冻结	−8.0 12/54	—
③ 同样的历史	−11.4 16/36	−12.2 0/36
④ PEMS-BAY 短窗口	−43.8 0/6	−27.5 0/6
⑤ 预测 336 步	+1.3 24/42	−3.1 6/42

在线更好　冻结更好　相差 ±5% 以内

收益中位数（%），正数 = 在线误差更低，小字是在线更好的条数。表 15–19：① 在线 W1024 对调参后的冻结；② 同一个在线对重训到 75% 的冻结（只看最后 20%）；③ 记忆限 1,024 步的在线 W96（离线没调参）对调参后的冻结 W1024；④ PatchTST · PEMS-BAY 在线 W96 对冻结 W96（训崩 3/12 → 0/12）；⑤ 预测 336 步（只有 DLinear，冻结没调参）。详见完整版第 8 节。

为什么 O 划分好得多

- 不是测的时间段不同：在大致同一段时间（每条序列最后约 20%）上，O 划分在线误差仍低 13%，T 划分打平（完整版表 11）。
- 是冻结模型的数据又旧又少：O 划分的冻结只用了前 20%，重训到 75% 就比在线好（表 15–19 第 ② 行）；T 划分的冻结本来就用了 60%–70%。

短窗口和成本

- 在线 W96 对冻结 W96：主表做法下 T 划分在线误差高 7%–14%，O 划分打平；学习率调小后 O 划分低 11%、T 划分低 5%（第一轮 6 组配置）。
- 学习率调小不会让更新更省：小学习率的在线 W1024 每次预测仍是冻结的约 6.6 倍。

还不能说的

- 定期重训和在线更新哪个更划算；同样历史下两边都调参后谁好；Electricity 的 O 划分为什么例外（一个几乎不变的变量占了冻结误差的 98%，去掉它重跑的实验 E 还没回来）。
- 范围窄：最多 7 个数据集，大多是 W1024、预测 96 步；中位数只作描述，不是统计检验。